

PERCOLIA



Structuration automatique de données

Louis HAUSEUX & Alban HAUSEUX

Board meeting #1, avec Antoine ALBRECHT et Stéphanie MORALES



Équipe fondatrice

Louis Hauseux

- ▶ Doctorat en informatique à Inria Sophia Antipolis.
- ▶ Normalien, double master en mathématiques fondamentales et appliquées.
- ▶ Conception et développement du noyau HGP-Clusterer.

Conseil scientifique & réseau

- ▶ **Josiane Zerubia** (Directrice de Recherche Inria, équipe AYANA).

Alban Hauseux

- ▶ Ingénieur IMT Atlantique, master en ingénierie financière à Paris-Dauphine.
- ▶ Expérience en finance quantitative, audit et contrôle de modèles.
- ▶ Industrialisation, intégration client et développement commercial.

La limite des méthodes actuelles de clustering

Le standard : DBSCAN et HDBSCAN

- ▶ Ces méthodes repèrent les zones denses, puis relient les points deux à deux.
- ▶ Elles sont rapides, disponibles dans les bibliothèques standards et très largement utilisées.

Le problème dans les scènes LiDAR réelles

- ▶ Le bruit peut former un pont entre deux structures distinctes.
- ▶ L'algorithme finit alors par fusionner des objets qui devraient rester séparés. C'est l'effet de chaînage.

Conséquence opérationnelle : Mauvaise segmentation, anomalies mal isolées, résultats difficiles à exploiter, corrections manuelles.



La rupture technique de Percolia

HGP-Clusterer généralise le principe du Single-Linkage

- ▶ Passage à l'ordre supérieur : les connexions ne sont plus évaluées entre deux points, mais à l'échelle d'un groupe.
- ▶ L'algorithme construit une hiérarchie de groupes à plusieurs échelles et retarde les fusions provoquées par le bruit.

Propriétés du moteur

- ▶ Sans entraînement ni données labellisées.
- ▶ Compatible avec des changements de capteur ou de domaine.
- ▶ Conçu pour de grands nuages de points.

Spécificité industrielle

- ▶ Des volumes, dimensions physiques ou modèles 3D peuvent guider la sélection des groupes.
- ▶ Le même moteur s'insère dans un pipeline existant sans réentraîner un modèle.

L. HAUSEUX, K. AVRACHENKOV, J. ZERUBIA, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 2026.



Le LiDAR comme premier marché

Point d'entrée commercial

- ▶ Jumeaux numériques, suivi d'actifs et inspection industrielle.
- ▶ Entreprises qui disposent déjà de scanners et d'un pipeline de traitement 3D.
- ▶ Scènes où le bruit et les objets imbriqués empêchent une séparation fiable.

Valeur mesurable

- ▶ Moins de fusions erronées.
- ▶ Moins de correction manuelle.
- ▶ Une étape de traitement plus facilement automatisable.


Exemple 1 : Détection d'anomalies de chantier (AIDetech)

Projet ISS de Marie Aspro avec Naval Group

- ▶ **Objectif** : Détection automatique d'anomalies sur chantiers navals.
- ▶ **Données** : Confrontation entre un **modèle 3D théorique** (chantier attendu) et des **captations LiDAR** (chantier réel – synthétique pour des besoins de confidentialité).
- ▶ **Collaboration Percolia** : Isoler les anomalies qui ne font pas partie du modèle théorique (ex. : casques de chantier, tuteurs, bâches).

Le verrou

- ▶ Nécessite un clustering assez fin prenant en compte le modèle 3D pour isoler proprement les anomalies de chantier.



Détection des anomalies (cubes et tuteurs colorés) par rapport au modèle 3D (en rouge) sur le benchmark de Marie ASPRO. © Marie ASPRO / Naval Group.



Du benchmark à la licence logicielle

1. Benchmark ou pilote

- ▶ Le client fournit quelques scans représentatifs.
- ▶ Percolia compare la qualité des groupes et le temps de calcul au pipeline existant.

2. Intégration

- ▶ Connexion aux formats du client.
- ▶ Configuration des contraintes géométriques ou du modèle 3D.

3. Revenu logiciel récurrent

- ▶ Licence annuelle installée chez le client.
- ▶ API lorsque le cloud convient aux données et aux contraintes de sécurité.



Au-delà du LiDAR

Un moteur de clustering pour plusieurs familles de données

- ▶ Le coeur mathématique travaille sur des données euclidiennes.
- ▶ Le nuage de points LiDAR constitue le premier produit commercial, avec un besoin industriel concret et observable.

Applications possibles

- ▶ Nuages de points et autres données euclidiennes.
- ▶ Vecteurs, embeddings et matrices de distances.
- ▶ Détection de communautés dans des graphes.