

PERCOLIA



Structuration automatique de données

Louis HAUSEUX et Alban HAUSEUX

Rencontre avec Anne-Sophie CARRESE et Arturo ANCIRA GARCÍA (Elaia)



Équipe fondatrice

Louis Hauseux

- ▶ Doctorat en informatique à Inria Sophia Antipolis
- ▶ Normalien, double master en mathématiques fondamentales et appliquées
- ▶ Conception et développement du noyau HGP-Clusterer


Conseil scientifique et réseau

- ▶ **Josiane Zerubia** (directrice de recherche Inria, équipe AYANA)

Alban Hauseux

- ▶ Ingénieur IMT Atlantique, master en ingénierie financière à Paris-Dauphine
- ▶ Expérience en finance quantitative, audit et contrôle de modèles
- ▶ Industrialisation, intégration client et développement commercial

Genèse du projet



Fil conducteur

Passer des interactions entre paires de points à des interactions d'ordre supérieur pour un *clustering* robuste au bruit

Publications EUSIPCO 2024, *Complex Networks* 2025, *ACM SIGMETRICS PER* 2025, *Applied Network Science* 2026

La limite des méthodes actuelles de *clustering*

Les standards DBSCAN et HDBSCAN

- ▶ Ces méthodes repèrent les zones denses puis relient les points deux à deux
- ▶ Elles sont rapides, disponibles dans les bibliothèques standards et très largement utilisées

Le problème dans les scènes LiDAR réelles

- ▶ Le bruit peut former un pont entre deux structures distinctes
- ▶ L'algorithme finit alors par fusionner des objets qui devraient rester séparés (effet de chaînage)

Conséquence opérationnelle Mauvaise segmentation, anomalies mal isolées, résultats difficiles à exploiter, corrections manuelles

La rupture technique de Percolia

HGP-Clusterer généralise le principe du *Single-Linkage*

- ▶ Passage à l'ordre supérieur avec des connexions évaluées à l'échelle d'un groupe et non plus entre deux points
- ▶ L'algorithme construit une hiérarchie de groupes à plusieurs échelles et retarde les fusions provoquées par le bruit

Propriétés du moteur

- ▶ Sans entraînement ni données labellisées
- ▶ Compatible avec des changements de capteur ou de domaine
- ▶ Conçu pour de grands nuages de points

Spécificité industrielle

- ▶ Des volumes, dimensions physiques ou modèles 3D peuvent guider la sélection des groupes
- ▶ Le même moteur s'insère dans un *pipeline* existant sans réentraîner un modèle

L. HAUSEUX, K. AVRACHENKOV, J. ZERUBIA, « Generalization of Single-Linkage with Higher-Order Interactions », *Applied Network Science*, 2026



Le LiDAR comme premier marché

Point d'entrée commercial

- ▶ Jumeaux numériques, suivi d'actifs et inspection industrielle
- ▶ Entreprises qui disposent déjà de scanners et d'un *pipeline* de traitement 3D
- ▶ Scènes où le bruit et les objets imbriqués empêchent une séparation fiable

Valeur mesurable

- ▶ Moins de fusions erronées
- ▶ Moins de correction manuelle
- ▶ Une étape de traitement plus facilement automatisable


Exemple 1 : Détection d'anomalies de chantier (AI Detech)

Projet ISS de Marie Aspro avec Naval Group

- ▶ **Objectif** Détection automatique d'anomalies sur chantiers navals
- ▶ **Données** Confrontation entre un **modèle 3D théorique** (chantier attendu) et des **captations LiDAR** (chantier réel – synthétique pour des besoins de confidentialité)
- ▶ **Collaboration Percolia** Isoler les anomalies qui ne font pas partie du modèle théorique (casques de chantier, tuteurs, bâches)

Le verrou

- ▶ Nécessite un *clustering* assez fin prenant en compte le modèle 3D pour isoler proprement les anomalies de chantier



Détection des anomalies (cubes et tuteurs colorés) par rapport au modèle 3D (en rouge) sur le *benchmark* de Marie ASPRO
© Marie ASPRO et Naval Group




Panoptique 3D : l'état de l'art est un *clustering*

Panoptique = la *classe* de chaque point + son *instance*

- ▶ L'instance s'apprenait de bout en bout, au prix d'annotations coûteuses
- ▶ **ALPINE** Une bonne sémantique puis, classe par classe, un **clustering classique** (graphe des k plus proches voisins, seuil, **composantes connexes**)
- ▶ **Geo-4D** Garde le schéma en 4D et y ajoute une **association géométrique** entre trames, elle aussi sans apprentissage

État de l'art en segmentation panoptique sur
LiDAR extérieur



C. SAUTIER *et al.*, « Is clustering enough for LiDAR instance segmentation? A state-of-the-art training-free baseline » (ALPINE), 2025

G. OH *et al.*, « Training-free global geometric association for 4D LiDAR panoptic segmentation » (Geo-4D), 2025

Exemple 2 : Détection d'obstacles d'un véhicule autonome (Milla)




Schéma reproduit d'après la diapositive « Détection obstacles » présentée par Milla aux Scientific Days, 25 septembre 2026, Pôle Alpha, Sophia Antipolis © Milla



Exemple 3 : Jumeaux numériques urbains (Greehill)

Inventaire intelligent des arbres


- ▶ Jumeaux numériques d'arbres urbains par LiDAR mobile
- ▶ Santé des arbres, chutes de branches, obstacles (lignes électriques, voies)

Le verrou


- ▶ Le feuillage se mêle aux lignes électriques, aux panneaux et aux façades

Interlocuteur Benjamin BERTA, responsable *machine learning* de Greehill

Clustering Percolia



Segmentation sémantique
(sol, bois, feuilles)



Séparation
des arbres



Modèle 3D
de chaque arbre

Images extraites d'une présentation de Gyula FEKETE, directeur technique de Greehill



Exemple 4 : Rétroconception (*reverse engineering*)

La rétroconception consiste à recréer le modèle numérique d'un objet existant à partir de sa numérisation 3D




Schéma adapté de la fig. 10.1 de W. GAO et G. LI, *Deep Learning for 3D Point Clouds*, Springer, 2025, p. 277

HGP-Clusterer face à HDBSCAN

Le principe

- ▶ **Hiérarchie** Le rayon r grandit, les groupes se forment puis fusionnent
- ▶ **IoU** Intersection sur union d'un groupe et d'un objet réel, de 0 à 1
- ▶ **Objet retrouvé** Un groupe de la hiérarchie dépasse un IoU de 0,5
- ▶ **Lecture** HGP à gauche, HDBSCAN à droite, même k

Des endroits difficiles

- ▶ Deux vélos près d'un bâtiment 08/002852
- ▶ Un piéton et deux vélos 06/000800
- ▶ Deux vélos imbriqués 08/001170
- ▶ Un piéton tout près d'un vélo 00/002140

À retenir HDBSCAN réunit trop tôt les objets voisins, HGP les retrouve tous
Pour la supériorité théorique de HGP, voir *Applied Network Science*, 2026

Données SemanticKITTI, HDBSCAN de scikit-learn

Trois voies d'accès au marché

1. Intégration

- ▶ *Benchmark*, intégration puis licence ou API
- ▶ Greehill, AI Detech, Milla, Hydro-Québec

2. Constructeurs LiDAR

- ▶ Notre moteur intégré au logiciel livré avec leurs scanners
- ▶ YellowScan, Artec 3D

3. Verticale complète


- ▶ Percolia propose elle-même le service complet, de la donnée brute au résultat final
- ▶ **Limite possible** Les constructeurs préfèrent en général garder la technologie en interne

Vers un modèle de fondation pour la 3D ?



- ▶ Un modèle de fondation est entraîné une seule fois sur des données massives sans annotation, puis réutilisé pour quantité de tâches
- ▶ Le texte a GPT, l'image a SAM, la 3D cherche encore le sien


Le nuage est un *artefact* du capteur



- ▶ La **densité** décroît avec la portée, s'y ajoutent les nappes de balayage et les **occultations**
- ▶ Un modèle point par point apprend donc *en même temps* la géométrie, le capteur, la densité, l'occultation **et** la sémantique
- ▶ **Hypothèse** C'est *une* raison centrale de la difficulté


Sémantique et instances : inverser l'ordre

Dans les exemples vus, comme dans l'état de l'art (ALPINE de Valeo AI), la sémantique vient d'abord et le *clustering* sépare ensuite les objets



Hypothèse Le *clustering* hiérarchique HGP est assez bon pour aider la sémantique

Un modèle de fondation guidé par la hiérarchie HGP



- ▶ Les unités du modèle ne sont plus les points du capteur mais les polyèdres de la hiérarchie HGP
- ▶ Même recette que pour le texte, le polyèdre comme alphabet et la hiérarchie comme grammaire
- ▶ Hypothèse à tester, projet en conception avec Zoltán KATÓ (université de Szeged) et Josiane ZERUBIA