

PERCOLIA



Structuration automatique de données

Louis HAUSEUX et Alban HAUSEUX

Rencontre avec Anne-Sophie CARRESE et Arturo ANCIRA GARCÍA (Elaia)



Équipe fondatrice

Louis Hauseux

- ▶ Doctorat en informatique à Inria Sophia Antipolis
- ▶ Normalien, double master de mathématiques
- ▶ Concepteur de HGP-Clusterer
- ▶ Médaille d'excellence de l'Université Côte d'Azur, 2^e prix ACM SIGMETRICS, finaliste du prix Pierre LAFFITTE


Conseil scientifique et réseau

- ▶ Josiane ZERUBIA, directrice de recherche Inria, équipe AYANA

Alban Hauseux

- ▶ Ingénieur IMT Atlantique, master d'ingénierie financière à Paris-Dauphine
- ▶ Finance quantitative, audit et contrôle de modèles
- ▶ Industrialisation, intégration client et développement commercial

Genèse du projet



Fil conducteur Des paires de points aux interactions d'ordre supérieur, pour un *clustering* robuste au bruit

Publications EUSIPCO 2024, *Complex Networks* 2025, *ACM SIGMETRICS PER* 2025, *Applied Network Science* 2026

La limite des méthodes actuelles de *clustering*

Les standards DBSCAN et HDBSCAN

- ▶ Repèrent les zones denses puis relient les points deux à deux
- ▶ Rapides, disponibles partout et très utilisés

Le problème dans les scènes LiDAR réelles

- ▶ Le bruit crée des ponts entre objets voisins
- ▶ Ces objets fusionnent alors (effet de chaînage)

Conséquence Mauvaise segmentation, anomalies mal isolées, corrections manuelles

La rupture technique de Percolia

HGP-Clusterer généralise le *Single-Linkage*

- ▶ Des connexions évaluées entre groupes de points, et non plus entre deux points
- ▶ Une hiérarchie de groupes à toutes les échelles, qui retarde les fusions dues au bruit

Propriétés du moteur

- ▶ Sans entraînement ni annotation
- ▶ Compatible avec un changement de capteur ou de domaine
- ▶ Conçu pour de grands nuages de points

Spécificité industrielle

- ▶ Volumes, dimensions ou modèles 3D guident le choix des groupes
- ▶ S'insère dans un *pipeline* existant

L. HAUSEUX, K. AVRACHENKOV, J. ZERUBIA, « Generalization of Single-Linkage with Higher-Order Interactions », *Applied Network Science*, 2026

Le LiDAR comme premier marché

Point d'entrée commercial

- ▶ Jumeaux numériques, suivi d'actifs, inspection industrielle
- ▶ Clients déjà équipés de scanners et d'un *pipeline* 3D
- ▶ Scènes bruitées aux objets imbriqués

Valeur mesurable

- ▶ Moins de fusions erronées
- ▶ Moins de corrections manuelles
- ▶ Une étape plus facile à automatiser


Exemple 1 : chantiers navals (AI Deteach)

Projet ISS avec Naval Group

- ▶ **Objectif** Détecter les anomalies de chantier
- ▶ **Données** Modèle 3D attendu face aux captations LiDAR (synthétiques par confidentialité)
- ▶ **Percolia** Isoler ce qui n'est pas dans le modèle (casques, tuteurs, bâches)

Le verrou

- ▶ Un *clustering* fin, guidé par le modèle 3D



Modèle 3D en rouge, anomalies en orange, vert et bleu
© Marie ASPRO et Naval Group

Interlocutrice Marie ASPRO, depuis la Fête des start-ups de l'ISS en novembre 2025


Exemple 2 : conduite autonome (Valeo AI)

ALPINE, l'état de l'art sur LiDAR extérieur

- ▶ **Panoptique** La classe de chaque point et son instance
- ▶ **Avant** Des instances apprises, au prix d'annotations coûteuses
- ▶ **ALPINE** La sémantique puis un *clustering* classique sans apprentissage, repris en 4D par Geo-4D

Le verrou

- ▶ Un graphe à rayon fixe, qui peut fusionner des objets proches




Chaîne d'ALPINE, de la sémantique aux instances

Interlocuteur Renaud MARLET, coauteur d'ALPINE, depuis le séminaire « Comment *hacker* (H)DBSCAN ? » donné chez Valeo AI en novembre 2025

C. SAUTIER *et al.*, « Is clustering enough for LiDAR instance segmentation? A state-of-the-art training-free baseline » (ALPINE), 2025

G. OH *et al.*, « Training-free global geometric association for 4D LiDAR panoptic segmentation » (Geo-4D), 2025

Exemple 3 : navette autonome (Milla)



D'après la présentation de Milla aux Scientific Days (Sophia Antipolis, septembre 2026) © Milla


Exemple 4 : arbres urbains (Greehill)

Inventaire intelligent des arbres

- ▶ Jumeaux numériques par LiDAR mobile
- ▶ Santé, chutes de branches, obstacles proches

Le verrou

- ▶ Le feuillage se mêle aux lignes électriques, aux panneaux et aux façades



Interlocuteur Benjamin BERTA, échanges en 2025 sur leur brique DBSCAN

Images extraites d'une présentation de Gyula FEKETE (Greehill), rencontré à l'école d'été SSRM 2024 à Veszprém

Exemple 5 : rétroconception

La rétroconception (*reverse engineering*) recrée le modèle numérique d'un objet existant à partir de sa numérisation 3D




Schéma adapté de la fig. 10.1 de W. GAO et G. LI, *Deep Learning for 3D Point Clouds*, Springer, 2025, p. 277

HGP-Clusterer face à HDBSCAN

Le principe

- ▶ **Hiérarchie** Le rayon r grandit, les groupes se forment puis fusionnent
- ▶ **IoU** Intersection sur union d'un groupe et d'un objet réel, de 0 à 1
- ▶ **Objet retrouvé** Un groupe de la hiérarchie dépasse un IoU de 0,5
- ▶ **Lecture** HGP à gauche, HDBSCAN à droite, même k

Des endroits difficiles

- ▶ Deux vélos près d'un bâtiment 08/002852
- ▶ Un piéton et deux vélos 06/000800
- ▶ Deux vélos imbriqués 08/001170
- ▶ Un piéton tout près d'un vélo 00/002140

À retenir HDBSCAN réunit trop tôt les objets voisins, HGP les retrouve tous
Pour la supériorité théorique de HGP, voir *Applied Network Science*, 2026

Données SemanticKITTI, HDBSCAN de scikit-learn

Trois voies d'accès au marché

1. Intégration

- ▶ *Benchmark*, intégration puis licence ou API
- ▶ Greehill, AI Detech, Milla, Hydro-Québec

2. Constructeurs LiDAR

- ▶ Notre moteur dans le logiciel de leurs scanners
- ▶ YellowScan, Artec 3D

3. Verticale complète


- ▶ Le service complet, de la donnée brute au résultat
- ▶ **Limite** Les constructeurs gardent souvent la technologie en interne

Vers un modèle de fondation pour la 3D ?



- ▶ Entraîné une fois sur des données massives sans annotation, puis réutilisé partout
- ▶ Le texte a GPT, l'image a SAM, la 3D cherche encore le sien

Le nuage est un artefact du capteur




- Densité décroissante avec la portée, nappes de balayage, occultations
- Un modèle point par point apprend à la fois la géométrie, le capteur, la densité, l'occultation et la sémantique

Hypothèse C'est *une* raison centrale de la difficulté


Sémantique et instances : inverser l'ordre

Dans nos exemples comme dans l'état de l'art, la sémantique vient d'abord et le *clustering* ensuite



Hypothèse Le *clustering* hiérarchique HGP est assez bon pour aider la sémantique

Un modèle de fondation guidé par HGP



- ▶ Les polyèdres de la hiérarchie HGP remplacent les points du capteur
- ▶ Même recette que le texte, le polyèdre pour alphabet, la hiérarchie pour grammaire
- ▶ Projet en conception avec Zoltán KATÓ (université de Szeged) et Josiane ZERUBIA