

PERCOLIA



Structuration automatique de données

Louis HAUSEUX et Alban HAUSEUX

Rencontre avec Anne-Sophie CARRESE et Arturo ANCIRA GARCÍA (Elaia)



Équipe fondatrice

Louis Hauseux

- ▶ Doctorat en informatique à Inria Sophia Antipolis
- ▶ Normalien, double master en mathématiques fondamentales et appliquées
- ▶ Conception et développement du noyau HGP-Clusterer


Conseil scientifique et réseau

- ▶ **Josiane Zerubia** (directrice de recherche Inria, équipe AYANA)

Alban Hauseux

- ▶ Ingénieur IMT Atlantique, master en ingénierie financière à Paris-Dauphine
- ▶ Expérience en finance quantitative, audit et contrôle de modèles
- ▶ Industrialisation, intégration client et développement commercial

Genèse du projet



Fil conducteur

Passer des interactions entre paires de points à des interactions d'ordre supérieur pour un *clustering* robuste au bruit

Publications EUSIPCO 2024, *Complex Networks* 2025, *ACM SIGMETRICS PER* 2025, *Applied Network Science* 2026

La limite des méthodes actuelles de *clustering*

Les standards DBSCAN et HDBSCAN

- ▶ Ces méthodes repèrent les zones denses puis relient les points deux à deux
- ▶ Elles sont rapides, disponibles dans les bibliothèques standards et très largement utilisées

Le problème dans les scènes LiDAR réelles

- ▶ Le bruit peut former un pont entre deux structures distinctes
- ▶ L'algorithme finit alors par fusionner des objets qui devraient rester séparés (effet de chaînage)

Conséquence opérationnelle Mauvaise segmentation, anomalies mal isolées, résultats difficiles à exploiter, corrections manuelles

La rupture technique de Percolia

HGP-Clusterer généralise le principe du *Single-Linkage*

- ▶ Passage à l'ordre supérieur avec des connexions évaluées à l'échelle d'un groupe et non plus entre deux points
- ▶ L'algorithme construit une hiérarchie de groupes à plusieurs échelles et retarde les fusions provoquées par le bruit

Propriétés du moteur

- ▶ Sans entraînement ni données labellisées
- ▶ Compatible avec des changements de capteur ou de domaine
- ▶ Conçu pour de grands nuages de points

Spécificité industrielle

- ▶ Des volumes, dimensions physiques ou modèles 3D peuvent guider la sélection des groupes
- ▶ Le même moteur s'insère dans un *pipeline* existant sans réentraîner un modèle

L. HAUSEUX, K. AVRACHENKOV, J. ZERUBIA, « Generalization of Single-Linkage with Higher-Order Interactions », *Applied Network Science*, 2026



Le LiDAR comme premier marché

Point d'entrée commercial

- ▶ Jumeaux numériques, suivi d'actifs et inspection industrielle
- ▶ Entreprises qui disposent déjà de scanners et d'un *pipeline* de traitement 3D
- ▶ Scènes où le bruit et les objets imbriqués empêchent une séparation fiable

Valeur mesurable

- ▶ Moins de fusions erronées
- ▶ Moins de correction manuelle
- ▶ Une étape de traitement plus facilement automatisable


Exemple 1 : Détection d'anomalies de chantier (AI Detech)

Projet ISS de Marie Aspro avec Naval Group

- ▶ **Objectif** Détection automatique d'anomalies sur chantiers navals
- ▶ **Données** Confrontation entre un **modèle 3D théorique** (chantier attendu) et des **captations LiDAR** (chantier réel – synthétique pour des besoins de confidentialité)
- ▶ **Collaboration Percolia** Isoler les anomalies qui ne font pas partie du modèle théorique (casques de chantier, tuteurs, bâches)

Le verrou

- ▶ Nécessite un *clustering* assez fin prenant en compte le modèle 3D pour isoler proprement les anomalies de chantier



Détection des anomalies (cubes et tuteurs colorés) par rapport au modèle 3D (en rouge) sur le *benchmark* de Marie ASPRO
© Marie ASPRO et Naval Group

Exemple 2 : Détection d'obstacles d'un véhicule autonome (Milla)




Schéma reproduit d'après la diapositive « Détection obstacles » présentée par Milla aux Scientific Days, 25 septembre 2026, Pôle Alpha, Sophia Antipolis © Milla



Exemple 3 : Jumeaux numériques urbains (Greehill)

Inventaire intelligent des arbres


- ▶ Jumeaux numériques d'arbres urbains par LiDAR mobile
- ▶ Santé des arbres, chutes de branches, obstacles (lignes électriques, voies)

Le verrou

- ▶ Le feuillage se mêle aux lignes électriques, aux panneaux et aux façades

Interlocuteur Benjamin BERTA, responsable *machine learning* de Greehill

Clustering Percolia



Images extraites d'une présentation de Gyula FEKETE, directeur technique de Greehill



Exemple 4 : Rétroconception (*reverse engineering*)

La rétroconception consiste à recréer le modèle numérique d'un objet existant à partir de sa numérisation 3D




Schéma adapté de la fig. 10.1 de W. GAO et G. LI, *Deep Learning for 3D Point Clouds*, Springer, 2025, p. 277



HGP-Clusterer face à HDBSCAN

Mêmes scènes LiDAR réelles et même paramètre k pour les deux hiérarchies

Scène (SemanticKITTI)	k	Objets retrouvés	
		HGP	HDBSCAN
Deux vélos (08/002852)	5	2 sur 2	1 sur 2
Deux vélos (08/001170)	5	2 sur 2	1 sur 2
Un piéton et deux vélos (06/000800)	10	3 sur 3	1 sur 3
Un piéton et un vélo (00/002140)	10	2 sur 2	1 sur 2
Total		9 sur 9	4 sur 9

À retenir HDBSCAN réunit les objets proches avant de les avoir isolés, HGP retrouve chaque objet dans sa hiérarchie

Objet retrouvé quand un groupe de la hiérarchie le recouvre à plus de 50 %

Données SemanticKITTI (CC BY-NC-SA), HDBSCAN de scikit-learn



Du *benchmark* à la licence logicielle

1. *Benchmark* ou pilote

- ▶ Le client fournit quelques *scans* représentatifs
- ▶ Percolia compare la qualité des groupes et le temps de calcul au *pipeline* existant

2. *Intégration*

- ▶ Connexion aux formats du client
- ▶ Configuration des contraintes géométriques ou du modèle 3D

3. Revenu logiciel récurrent

- ▶ Licence annuelle installée chez le client
- ▶ API lorsque le *cloud* convient aux données et aux contraintes de sécurité

Trois voies d'accès au marché

1. Intégration

- ▶ *Benchmark*, intégration puis licence ou API
- ▶ Greehill, AI Detech, Milla, Hydro-Québec

2. Constructeurs LiDAR

- ▶ Notre moteur intégré au logiciel livré avec leurs scanners
- ▶ YellowScan, Artec 3D

3. Verticale complète

- ▶ Percolia propose elle-même le service complet, de la donnée brute au résultat final
- ▶ **Limite possible** Les constructeurs préfèrent en général garder la technologie en interne



Au-delà du LiDAR

Un moteur de *clustering* pour plusieurs familles de données

- ▶ Le cœur mathématique travaille sur des données euclidiennes
- ▶ Le nuage de points LiDAR constitue le premier produit commercial, avec un besoin industriel concret et observable

Applications possibles

- ▶ Nuages de points et autres données euclidiennes
- ▶ Vecteurs, *embeddings* et matrices de distances
- ▶ Détection de communautés dans des graphes