

PERCOLIA



Structuration automatique de données

Louis HAUSEUX et Alban HAUSEUX

Rencontre avec Anne-Sophie CARRESE et Arturo ANCIRA GARCÍA (Elaia)



Équipe fondatrice

Louis Hauseux

- ▶ Doctorat en informatique à Inria Sophia Antipolis
- ▶ Normalien, double master de mathématiques
- ▶ Concepteur de HGP-Clusterer
- ▶ Médaille d'excellence de l'Université Côte d'Azur, 2^e prix ACM SIGMETRICS, finaliste du prix Pierre LAFFITTE


Conseil scientifique et réseau

- ▶ Josiane ZERUBIA, directrice de recherche Inria, équipe AYANA

Alban Hauseux

- ▶ Ingénieur IMT Atlantique, master d'ingénierie financière à Paris-Dauphine
- ▶ Finance quantitative, audit et contrôle de modèles
- ▶ Industrialisation, intégration client et développement commercial

Genèse du projet



Fil conducteur Des paires de points aux interactions d'ordre supérieur, pour un *clustering* robuste au bruit

Publications EUSIPCO 2024, *Complex Networks* 2025, *ACM SIGMETRICS PER* 2025, *Applied Network Science* 2026


La limite des méthodes actuelles de *clustering*

Les standards DBSCAN et HDBSCAN

- ▶ Repèrent les zones denses puis relient les points deux à deux
- ▶ Rapides, disponibles partout et très utilisés

Le problème dans les scènes LiDAR réelles


- ▶ Le bruit crée des ponts entre objets voisins
- ▶ Ces objets fusionnent alors (effet de chaînage)



Nuage brut



HDBSCAN



Amas en couleur, bruit en gris

Conséquence Mauvaise segmentation, anomalies mal isolées, corrections manuelles

La rupture technique de Percolia

HGP-Clusterer généralise le *Single-Linkage*

- ▶ Des connexions évaluées entre groupes de points, et non plus entre deux points
- ▶ Une hiérarchie de groupes à toutes les échelles, qui retarde les fusions dues au bruit

Propriétés du moteur

- ▶ Sans entraînement ni annotation
- ▶ Compatible avec un changement de capteur ou de domaine
- ▶ Conçu pour de grands nuages de points

Spécificité industrielle

- ▶ Volumes, dimensions ou modèles 3D guident le choix des groupes
- ▶ S'insère dans un *pipeline* existant

L. HAUSEUX, K. AVRACHENKOV, J. ZERUBIA, « Generalization of Single-Linkage with Higher-Order Interactions », *Applied Network Science*, 2026

Le LiDAR comme premier marché

Point d'entrée commercial


- ▶ Jumeaux numériques, suivi d'actifs, inspection industrielle
- ▶ Clients déjà équipés de scanners et d'un *pipeline* 3D
- ▶ Scènes bruitées aux objets imbriqués

Valeur mesurable

- ▶ Moins de fusions erronées
- ▶ Moins de corrections manuelles
- ▶ Une étape plus facile à automatiser

Deux voies d'accès au marché

Roadmap produit



Clients potentiels



Verticale complète

- Le service complet, de la donnée brute au résultat


Exemple 1 : chantiers navals (AI Detech)

Projet ISS avec Naval Group

- ▶ **Objectif** Détecter les anomalies de chantier
- ▶ **Données** Modèle 3D attendu face aux captations LiDAR (synthétiques par confidentialité)
- ▶ **Percolia** Isoler ce qui n'est pas dans le modèle (casques, tuteurs, bâches)

Le verrou

- ▶ Un *clustering* fin, guidé par le modèle 3D



Modèle 3D en rouge, anomalies en orange, vert et bleu
© Marie ASPRO et Naval Group

Interlocutrice Marie ASPRO, depuis la Fête des start-ups de l'ISS en novembre 2025

Exemple 2 : conduite autonome (Valeo AI)

ALPINE, l'état de l'art sur LiDAR extérieur

- ▶ **Panoptique** La classe de chaque point et son instance
- ▶ **Avant** Des instances apprises, au prix d'annotations coûteuses
- ▶ **ALPINE** La sémantique puis un *clustering* classique sans apprentissage, repris en 4D par Geo-4D


Le verrou

- ▶ Un graphe à rayon fixe, qui peut fusionner des objets proches

Interlocuteur Renaud MARLET, coauteur d'ALPINE, depuis le séminaire « Comment *hacker* (H)DBSCAN ? » donné chez Valeo AI en novembre 2025


C. SAUTIER *et al.*, « Is clustering enough for LiDAR instance segmentation? A state-of-the-art training-free baseline » (ALPINE), 2025

G. OH *et al.*, « Training-free global geometric association for 4D LiDAR panoptic segmentation » (Geo-4D), 2025



Chaîne d'ALPINE, de la sémantique aux instances

Exemple 3 : navette autonome (Milla)



D'après la présentation de Milla aux Scientific Days (Sophia Antipolis, septembre 2026) © Milla


Exemple 4 : arbres urbains (Greehill)

Inventaire intelligent des arbres

- ▶ Jumeaux numériques par LiDAR mobile
- ▶ Santé, chutes de branches, obstacles proches

Le verrou

- ▶ Le feuillage se mêle aux lignes électriques, aux panneaux et aux façades



Interlocuteur Benjamin BERTA, échanges en 2025 sur leur brique DBSCAN

Images extraites d'une présentation de Gyula FEKETE (Greehill), rencontré à l'école d'été SSRM 2024 à Veszprém

Exemple 5 : rétroconception

La rétroconception (*reverse engineering*) recrée le modèle numérique d'un objet existant à partir de sa numérisation 3D




Schéma adapté de la fig. 10.1 de W. GAO et G. LI, *Deep Learning for 3D Point Clouds*, Springer, 2025, p. 277

HGP-Clusterer face à HDBSCAN

Le principe

- ▶ **Hiérarchie** Le rayon r grandit, les groupes se forment puis fusionnent
- ▶ **IoU** Intersection sur union d'un groupe et d'un objet réel, de 0 à 1
- ▶ **Objet retrouvé** Un groupe de la hiérarchie dépasse un IoU de 0,5
- ▶ **Lecture** HGP à gauche, HDBSCAN à droite, même k

Des endroits difficiles

- ▶ Deux vélos près d'un bâtiment 08/002852
- ▶ Un piéton et deux vélos 06/000800
- ▶ Deux vélos imbriqués 08/001170
- ▶ Un piéton tout près d'un vélo 00/002140

À retenir HDBSCAN réunit trop tôt les objets voisins, HGP les retrouve tous
Pour la supériorité théorique de HGP, voir *Applied Network Science*, 2026


Données SemanticKITTI, HDBSCAN de scikit-learn

Vers un modèle de fondation pour la 3D ?



- ▶ Entraîné une fois sur des données massives sans annotation, puis réutilisé partout
- ▶ Le texte a GPT, l'image a SAM, la 3D cherche encore le sien

Le nuage est un artefact du capteur




- Densité décroissante avec la portée, nappes de balayage, occultations
- Un modèle point par point apprend à la fois la géométrie, le capteur, la densité, l'occultation et la sémantique

Hypothèse C'est *une* raison centrale de la difficulté


Sémantique et instances : inverser l'ordre

Dans nos exemples comme dans l'état de l'art, la sémantique vient d'abord et le *clustering* ensuite



Hypothèse Le *clustering* hiérarchique HGP est assez bon pour aider la sémantique

Un modèle de fondation guidé par HGP



- ▶ Les polyèdres de la hiérarchie HGP remplacent les points du capteur
- ▶ Même recette que le texte, le polyèdre pour alphabet, la hiérarchie pour grammaire
- ▶ Projet en conception avec Zoltán KATÓ (université de Szeged) et Josiane ZERUBIA

Merci



Slides de la soutenance de thèse du 8 septembre 2026

- 01 Prologue : une ancienne énigme
- 02 Du *Single-Linkage* à ses fondements
- 03 Monter à l'ordre supérieur : la hiérarchie K -NN exacte
- 04 La percolation comme mesure de performance
- 05 Applications : LiDAR 3D et 4D, sans apprentissage
- 06 Vers des données davantage structurées
- 07 Perspectives : la voie hiérarchique
- 08 Conclusion, publications et bibliographie

01

Prologue : une ancienne énigme





Une ancienne énigme...

Un classificateur non-supervisé utilisant les
complexes simpliciaux
(avec une application à la *stylométrie*).

LOUIS HAUSEUX
Encadré par BARTŁOMIEJ BŁASZCZYSZYN



juillet 2017

Avant-propos

Stage à l'Inria Paris, équipe DYOGENE-MATHNET [HAL 17]

[HAL 17] L. Hauseux (encadré par B. Błaszczyszyn), « Un classificateur non supervisé utilisant les complexes simpliciaux », Inria Paris, 2017. HAL : hal-01597846.

Le sujet à la mode : l'homologie *persistante*




Faire croître un rayon r ; regarder les structures **naître, vivre, mourir** [Ghrist 08] [ToMATo 13]

[Ghrist 08] R. Ghrist, « Barcodes : the persistent topology of data », Bulletin of the AMS, 2008.

[ToMATo 13] F. Chazal, L. J. Guibas, S. Y. Oudot, P. Skraba, « Persistence-based clustering in Riemannian manifolds » (ToMATo), *J. ACM*, 60(6), art. 41, 2013.



...avec une application à la *stylométrie*




- ▶ Une matrice de **Gram** : similarité 500×500 entre articles de presse [HAL 17]
- ▶ **5 auteurs** anonymes, 100 articles chacun (statistiques de style : vocabulaire, catégories grammaticales, ponctuation, etc.)
- ▶ **But (non supervisé)** : rendre à chaque auteur ses 100 articles

Ici, les articles sont *triés* par auteur ; l'algorithme, lui, ne voit qu'une matrice mélangée



Une heuristique inspirée de la persistance




- Faire croître le seuil de similarité
- Observer les composantes « **triangles-connexes** »
(des k -simplexes recollés par facettes)
- Les voir **naître, grandir, fusionner**
- S'arrêter : une proportion P est couverte

Les « polyèdres » retournés ($k = 2$) [HAL 17]

[HAL 17] L. Hauseux (encadré par B. Błaszczyszyn), « Un classificateur non supervisé utilisant les complexes simpliciaux », Inria Paris, 2017. HAL : hal-01597846.



Et... cela marche bien




- ▶ **2 auteurs** : 1 erreur, 1 article non classé (sur 100)
- ▶ Mieux que l'algorithme des *k*-moyennes...
- ▶ ... et que des mélanges gaussiens *semi-supervisés*
- ▶ Et sur **5 auteurs** : 4 amas retrouvés

Analyse en composantes principales : deux auteurs sur cinq



Stylométrie 2017 : le cas à 5 auteurs



- ▶ 5 auteurs $\times$ 40 textes ($P = 70\%$, $k = 5$)
- ▶ 4 classes correctement identifiées...
- ▶ ... mais la 4^e (textes 120–159) est manquée
- ▶ Ronds noirs : non classés ; étoiles : affectés à plusieurs classes


02

Du *Single-Linkage* à ses fondements



Le *clustering* sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^p$

Modèle de Hartigan [Hartigan 81] : les amas de forte densité




[Hartigan 81] J. A. Hartigan, « Consistency of Single Linkage for high-density clusters », JASA, 1981.


[Campello 13] R. Campello, D. Moulavi, J. Sander, « Density-based clustering based on hierarchical density estimates » (HDBSCAN), PAKDD, 2013.



Deux exemples issus de la thèse



Cosmologie 3D : filaments de galaxies [CN 23]



Huiles d'olive ($\mathbb{R}^8$) : hiérarchie obtenue
[EUSIPCO 24] [ANS 26]

[CN 23] L. Hauseux, K. Avrachenkov, J. Zerubia, « Graph based approach for galaxy filament extraction », *Complex Networks & Their Applications*, Menton, 2023.


[EUSIPCO 24] L. Hauseux, K. Avrachenkov, J. Zerubia, « Benefits of hypergraphs for density-based clustering », *EUSIPCO*, Lyon, 2024.

[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.

Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau $\{f \geq \lambda\}$


Arbre hiérarchique




C_1

Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau $\{f \geq \lambda\}$




Arbre hiérarchique




Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau $\{f \geq \lambda\}$




Arbre hiérarchique




Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau $\{f \geq \lambda\}$



Arbre hiérarchique





En pratique : estimer la densité

$$\hat{f} \leftarrow \hat{f}_{K\text{-NN}}$$

Estimateur des K plus proches voisins [Biau–Devroye 15]


$$\forall y \in \mathbb{R}^p, \quad \hat{f}_{K\text{-NN}}(y) = \frac{K}{n \omega_p r_K(y)^p}$$

$$r_K(y) = \min \{r \geq 0 \mid |B(y, r) \cap (\mathcal{X} \setminus \{y\})| \geq K\}$$

- ▶ y : un point de l'espace, du nuage ou non
- ▶ n : nombre de points de $\mathcal{X}$
- ▶ ω_p : volume de la boule unité de $\mathbb{R}^p$
- ▶ $r_K(y)$: distance de y à son K^{e} plus proche voisin ; si $y \in \mathcal{X}$, on exclut y lui-même




Le cas $K = 1$: un « miracle » géométrique





Le cas $K = 1$: un « miracle » géométrique




$$\hat{\lambda}(y) \geq \lambda_0$$
$$\Leftrightarrow r_1(y) \leq r_0$$

Ensembles de niveau
= **modèle booléen** [Meester–Roy 96]



Le cas $K = 1$: un « miracle » géométrique




$$\hat{\lambda}(y) \geq \lambda_0$$
$$\Leftrightarrow r_1(y) \leq r_0$$

Amas de forte densité
= **composantes connexes**
d'un **graphe géométrique** [Penrose 03]



Le cas $K = 1$: un « miracle » géométrique




$$r_1(y) \leq r_0$$

Amas de forte densité
= **composantes connexes**
d'un **graphe géométrique** [Penrose 03]



Le cas $K = 1$: un « miracle » géométrique




$$r_1(y) \leq r_0$$

Amas de forte densité
= **composantes connexes**
de l'**arbre minimum couvrant** élagué



L'arbre minimum couvrant et la triangulation de Delaunay

Cette hiérarchie a un nom :
le **Single-Linkage** [Florek 51]
[Gower–Ross 69]



L'arbre minimum couvrant euclidien
est un **sous-graphe** de GABRIEL,
lui-même sous-graphe de DELAUNAY
[Boissonnat 18] :

arbre minimum couvrant
 $\subseteq$ GABRIEL $\subseteq$ DELAUNAY


Dans le plan $\mathbb{R}^2$: $\mathcal{O}(n \log n)$

[Florek 51] K. Florek, J. Łukaszewicz, J. Perkal, H. Steinhaus, S. Zubrzycki, « Sur la liaison et la division des points d'un ensemble fini », Colloq. Math., 1951.

[Gower–Ross 69] J. C. Gower, G. J. S. Ross, « Minimum spanning trees and Single-Linkage cluster analysis », JRSS C, 1969.

[Boissonnat 18] J.-D. Boissonnat, F. Chazal, M. Yvinec, *Geometric and Topological Inference*, Cambridge University Press, 2018.

L'effet de chaînage et le *Robust Single-Linkage*




Effet de chaînage : une chaîne de points suffit à fusionner deux amas

Robust Single-Linkage

[Chaudhuri–Dasgupta 10] :

- ▶ La *core distance* $r_K(x)$ estime la densité locale
- ▶ La distance devient la *mutual reachability*
- ▶ Les points isolés sont repoussés

Les descendants : DBSCAN, puis HDBSCAN



DBSCAN [Ester 96] : points *cœurs* ($r_K(x) \leq r$) vs. points *accessibles* : réintègre la frontière des amas

HDBSCAN [Campello 13] : fait varier le seuil r continûment et extrait les amas par excès de masse

$$E(C) = \int_C (f(x) - \lambda) dx$$

[Ester 96] M. Ester, H.-P. Kriegel, J. Sander, X. Xu, « A density-based algorithm for discovering clusters » (DBSCAN), KDD, 1996.

[Campello 13] R. Campello, D. Moulavi, J. Sander, « Density-based clustering based on hierarchical density estimates » (HDBSCAN), PAKDD, 2013.


03

Monter à l'**ordre supérieur** : la hiérarchie K -NN exacte




Que font Robust SL et (H)DBSCAN pour $K = 2$?

Nuage de points et boules de rayon r



Arbre hiérarchique obtenu




Un dendrogramme **plat** : toute l'information hiérarchique fine est perdue




La vraie hiérarchie 2-NN : échelle r

Les 2-intersections de boules au niveau r



Arbre hiérarchique




Étape 1 : les 7 segments fusionnent au seuil r



La vraie hiérarchie 2-NN : échelle r'

Triangles et 3-intersections à r'



Arbre hiérarchique




Étape 2 : fusion des triangles à r' via les 3-intersections. L'arête CD reste isolée




La vraie hiérarchie 2-NN : échelle r''

Connexité globale à r''




Arbre hiérarchique




Étape 3 : connexité globale à r'' par les points de tangence

Robust SL ($K = 2$)



Vraie hiérarchie 2-NN




Une asymétrie : condition d'ordre K sur les **points**, mais connexité d'ordre 1 par les **arêtes**



La réparation : le complexe de Čech et les K -polyèdres

- **Graphe géométrique** $\longrightarrow$ **complexe de Čech** :
un K -simplexe $\iff K + 1$ boules d'intersection non vide
- **Composantes connexes** $\longrightarrow$ **K -polyèdres** :
des $(K - 1)$ -simplexes recollés par des K -simplexes
- Pour $K \geq 2$, les amas peuvent **se recouvrir**

Théorème [ANS 26] [EUSIPCO 24] : à tout niveau, les K -polyèdres identifient *exactement* les amas discrets de forte densité de l'estimateur $\hat{f}_{K\text{-NN}}$. Pour $K = 1$: le *Single-Linkage*




[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.
[EUSIPCO 24] L. Hauseux, K. Avrachenkov, J. Zerubia, « Benefits of hypergraphs for density-based clustering », *EUSIPCO*, Lyon, 2024.


Qui provoque les fusions ? La condition de Gabriel

Arête de l'arbre minimum couvrant $\longrightarrow$ simplexe K -séparant

- **Définition [ANS 26]** : un simplexe est dit **K -séparant** s'il provoque une fusion K -NN
- **Cas $K = 1$** : les 1-séparants sont exactement les arêtes de l'arbre minimum couvrant
- **Définition [ANS 26]** : un K -simplexe est dit de **Gabriel** si sa miniboule ne contient aucun autre point
- **Théorème [ANS 26]** : tout simplexe K -séparant est de GABRIEL



Triangle de Gabriel (boule vide)



Non-Gabriel (boule non vide)

[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.



K -arbre couvrant et mosaïque de Delaunay d'ordre K

- **Fusions critiques** : les simplexes K -séparants, tous K -GABRIEL (boule minimale vide)
- **Arbre couvrant** $\longrightarrow$ K -arbre couvrant : élagué à r , il redonne les K -polyèdres [ANS 26]
- **Delaunay** $\longrightarrow$ **mosaïque d'ordre K** : elle porte tous les simplexes K -GABRIEL [Edelsbrunner–Osang 23]
- Pour $K = 2$: tout se lit dans DELAUNAY, en $\mathcal{O}(n \log n)$ dans le plan


Analogie ordre 1 vs. ordre K

	$K = 1$	$K \geq 2$
Sommets	points	$(K - 1)$ -simplexes
Fusions	arêtes	K -simplexes
Condition	arête GABRIEL	K -GABRIEL
Domaine	DELAUNAY	DELAUNAY d'ordre K

[Edelsbrunner–Osang 23] H. Edelsbrunner, G. Osang, « A simple algorithm for higher-order Delaunay mosaics and alpha shapes », *Algorithmica*, 2023.
 [ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.



Pourquoi Gabriel plutôt que la mosaïque de Delaunay d'ordre supérieur ?




- ▶ Quasi dégénérée, la sphère circonscrite admet des témoins **arbitrairement lointains** ; ceux de la *miniball* sont **localisables**
- ▶ Une décomposition en **paires bien séparées** [Callahan–Kosaraju 95] élimine alors des **blocs** de candidats **en parallèle** ; DELAUNAY reste séquentiel

[Callahan–Kosaraju 95] P. B. Callahan, S. R. Kosaraju, « A decomposition of multidimensional point sets with applications to k -nearest-neighbors and n -body potential fields », *J. ACM*, 42(1), 1995.



Banc d'essai SIPU : toutes choses égales par ailleurs




Même $\text{min_cluster_size} = \sqrt{n}$, même excès de masse :
la seule différence est la **connexité triangulaire**

Jeu	HDBSCAN	2-polyèdres
a2	0,762	0,834
a3	0,696	0,831
d31	0,660	0,835
s2	0,780	0,842
s3	0,251	0,418
birch2	0,996	0,998


ARI ; grille : vérité, HDBSCAN, notre algorithme



En pratique ($K = 2$) : les huiles d'olive italiennes [Forina 83]



HDBSCAN : 3 macrorégions



2-polyèdres : **8 provinces identifiées**
parmi les 72 % de points classés

Au-delà de l'état de l'art [Rolle–Scoccola 24] [ANS 26]

[Forina 83] M. Forina, C. Armanino, S. Lanteri, E. Tiscornia, « Classification of olive oils from their fatty acid composition », 1983 (jeu de données).

[Rolle–Scoccola 24] A. Rolle, L. Scoccola, « Stable and consistent density-based clustering via multiparameter persistence » (Persistable), *JMLR*, 25(258), 2024.

[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.



Huiles d'olive : la matrice de confusion

Pers./Ours	1	2	3	4	5	6	7	8	9	Miss.
N. Apulia	12/24	0/0	0/0	-	0/0	0/0	0/0	0/0	0/0	13/1
Calabria	0/0	7/25	1/2	-	0/0	0/0	0/0	0/0	0/0	48/29
S. Apulia	0/0	0/0	100/145	-	0/0	0/0	0/0	0/0	0/0	106/61
Sicilia	3/6	0/1	0/2	-	0/0	0/0	0/0	0/0	0/0	33/27
Inl. Sard.	0/0	0/0	0/0	-	51/62	0/0	0/0	0/0	0/0	14/3
Coast S.	0/0	0/0	0/0	-	0/2	19/29	0/0	0/0	0/0	14/2
E. Ligur.	0/0	0/0	0/0	-	0/0	0/0	14/32	1/2	0/1	35/15
W. Ligur.	0/0	0/0	0/0	-	0/0	0/0	0/0	29/33	0/0	21/17
Umbria	0/0	0/0	0/0	-	0/0	0/0	0/0	0/0	42/46	9/5

- ▶ 412/572 points classés (72 %), dont 96,1 % correctement
- ▶ Persistable [Rolle–Scoccola 24] : 49 % classés seulement
- ▶ En partition exhaustive : ARI 0,890 contre 0,848


[Rolle–Scoccola 24] A. Rolle, L. Scoccola, « Stable and consistent density-based clustering via multiparameter persistence » (Persistable), *JMLR*, 25(258), 2024.

04

La **percolation** comme mesure de performance



Le phénomène au cœur de tout : la percolation continue




$$r < r_c$$

$$r = r_c$$

$$r > r_c$$


Au-delà d'un seuil critique, une **composante géante** (en rouge) émerge [Penrose 03]

Pourquoi le *Single-Linkage* échoue en dimension ≥ 2



Deux amas denses, A et B (les carrés), sur un fond de faible densité


Pourquoi le *Single-Linkage* échoue en dimension ≥ 2



Arbre couvrant élagué au rayon r_1 : la percolation a lieu dans chaque carré, pas sur le fond




Pourquoi le *Single-Linkage* échoue en dimension ≥ 2



Au rayon $r_2 > r_1$, le fond percole aussi : A et B fusionnent *avant* d'avoir été entièrement récupérés



La fraction récupérable




- En abscisse : l'intensité λ ; en ordonnée : la fraction des points dans la **composante géante**
- Sous le seuil critique λ_c : rien
- La **fraction récupérable** d'un amas se lit sur la courbe

Fraction de points dans la composante géante [ANS 26]



Quantifier : la *vitesse de percolation*



$$v = \frac{\lambda_c}{\lambda_{1-\epsilon}}$$

- $\lambda_{1-\epsilon}$: l'amas est presque **entier**
- Plus v est **proche de 1**, meilleur est l'algorithme
[SIGMETRICS SRC 24] [CN 24]

Probabilité de percolation des K -polyèdres [ANS 26]

[SIGMETRICS SRC 24] L. Hauseux, « How can we theoretically measure the performance of density-based clustering algorithms ? », ACM SIGMETRICS SRC, Venice, 2024 (2^e prix).

[CN 24] L. Hauseux, K. Avrachenkov, J. Zerubia, « Hypergraphs, percolation and hierarchical clustering », *Complex Networks & Their Applications*, Istanbul, 2024.

[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.



Vitesses de percolation mesurées

K	$p = 2$			$p = 3$			$p = 4$		
	HGP	Robust SL	DBSCAN	HGP	Robust SL	DBSCAN	HGP	Robust SL	DBSCAN
1	0,735	0,735	0,735	0,563	0,563	0,563	0,362	0,362	0,362
2	0,779	0,689	0,735	0,646	0,462	0,563	0,451	0,271	0,362
3	0,800	0,632	0,753	0,690	0,412	0,582	0,497	0,247	0,378
4	0,817	0,598	0,767	0,714	0,400	0,605	0,500	0,246	0,409
5	0,826	0,584	0,779	0,732	0,399	0,625	0,534	0,236	0,415


Mesures des vitesses de percolation **[ANS 26]**

- ▶ **K -polyèdres** : la vitesse **croît** avec K , en dimension 2, 3 et 4
- ▶ **Robust SL** : elle **décroît** ; élaguer la frontière, c'est jeter une part de l'amas
- ▶ **DBSCAN** : il réintègre cette frontière élaguée, mais ses cœurs percolent trop tôt


[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.



Vitesses de percolation : *Robust Single-Linkage* et DBSCAN



Robust SL : la percolation converge trop lentement vers 1



DBSCAN : frontière réintégrée, mais les cœurs percolent trop tôt

$n = 100\,000$ points uniformes, 100 tirages ; $\hat{v} = \hat{\lambda}_\varepsilon / \hat{\lambda}_{1-\varepsilon}$, $\varepsilon = 3\%$; repère 2D, $K = 1$: $\lambda_c \approx 1,44$



Quand $K \rightarrow +\infty$: la fenêtre gaussienne


- ▶ Dans la fenêtre $\mu = K + a\sqrt{K}$, les niveaux K -NN convergent vers les **excursions** $E_a = \{G_p \geq -a\}$ d'un champ gaussien
- ▶ Covariance du champ : le volume d'intersection de deux boules
- ▶ Les trois algorithmes ne diffèrent que par l'**ordre des opérations** : dilater puis connecter (cœurs, DBSCAN) vs. connecter puis dilater (polyèdres)
- ▶ Seuils de bruit : $a_c^{\text{poly}} \geq a_c^{\text{core}}$, vitesse asymptotiquement meilleure pour les K -polyèdres



Schilder dans l'espace de Cameron–Martin

L'espace de CAMERON–MARTIN $\mathcal{H}_p$ [Cameron–Martin 44] : les déformations h du champ G_p d'énergie finie $\|h\|_{\mathcal{H}_p}^2$ — le RKHS de sa covariance [Berlinet–Thomas-Agnan 04]

$$\text{SCHILDER [Schilder 66]} : \quad \mathbb{P}(G_p \approx a h) \approx \exp\left(-\frac{a^2}{2} \|h\|_{\mathcal{H}_p}^2\right)$$



Un point qui plonge coûte 1 ; la boule entière coûte $1/U_p$, l'inverse de sa **capacité** ($1/U_2 \approx 3,4$)

Ébauche : la borne globale (lemme de Peierls) reste à écrire

[Cameron–Martin 44] R. H. Cameron, W. T. Martin, « Transformations of Wiener integrals under translations », *Annals of Mathematics*, 45(2), 1944.

[Berlinet–Thomas-Agnan 04] A. Berlinet, C. Thomas-Agnan, *Reproducing Kernel Hilbert Spaces in Probability and Statistics*, Kluwer, 2004.

[Schilder 66] M. Schilder, « Some asymptotic formulas for Wiener integrals », *Transactions of the AMS*, 125(1), 1966.



Le théorème de Schilder, énoncé

G_p : le champ gaussien limite, centré, de covariance $\rho_p(x - y) = |B(x, \frac{1}{2}) \cap B(y, \frac{1}{2})| / |B(0, \frac{1}{2})|$, à trajectoires continues sur un compact $\Gamma \subset \mathbb{R}^p$; $\mathcal{H}_p$ son espace de CAMERON–MARTIN, de norme $\|\cdot\|_{\mathcal{H}_p}$

Théorème (SCHILDER [Schilder 66] ; forme gaussienne [Dembo–Zeitouni 10]). Pour tout borélien $A \subseteq \mathcal{C}(\Gamma, \mathbb{R})$, d'intérieur $\overset{\circ}{A}$ et d'adhérence $\overline{A}$, quand $a \rightarrow +\infty$:

$$\liminf_{a \rightarrow +\infty} \frac{1}{a^2} \log \mathbb{P}(G_p \in aA) \geq - \inf_{h \in \overset{\circ}{A}} \frac{1}{2} \|h\|_{\mathcal{H}_p}^2,$$

$$\limsup_{a \rightarrow +\infty} \frac{1}{a^2} \log \mathbb{P}(G_p \in aA) \leq - \inf_{h \in \overline{A}} \frac{1}{2} \|h\|_{\mathcal{H}_p}^2.$$

- Autrement dit : $\{G_p/a\}_{a>0}$ satisfait un **principe de grandes déviations** de vitesse a^2 et de fonction de taux $I(h) = \frac{1}{2} \|h\|_{\mathcal{H}_p}^2$, valant $+\infty$ hors de $\mathcal{H}_p$

[Schilder 66] M. Schilder, « Some asymptotic formulas for Wiener integrals », *Transactions of the AMS*, 125(1), 1966.

[Dembo–Zeitouni 10] A. Dembo, O. Zeitouni, *Large Deviations Techniques and Applications*, 2^e éd., Springer, 2010.


05

Applications : LiDAR 3D et 4D, sans apprentissage



La hiérarchie devient un espace de résolution

- ▶ L'arbre hiérarchique n'est pas qu'une sortie : on peut y **injecter des *a priori*** géométriques
- ▶ **Détection d'anomalies 3D** : comparaison au modèle théorique du navire
- ▶ Banc d'essai sur 2 000 000 points : objets étrangers **parfaitement isolés**, sans aucun apprentissage




Modèle de référence en rouge, anomalies en couleurs
[AYANA RA 25]
© Naval Group

En collaboration avec Marie ASPRO (Inria Startup Studio)



Nos premiers résultats : 3D




A priori géométriques appliqués aux volumes des instances, sur SemanticKITTI [SemanticKITTI 19]

[SemanticKITTI 19] J. Behley *et al.*, « SemanticKITTI : A Dataset for Semantic Scene Understanding of LiDAR Sequences », ICCV, 2019.




Nos premiers résultats : 4D

Vérité terrain



Notre algorithme



SemanticKITTI [SemanticKITTI 19], 200 trames

suivi par **transport optimal** + filtre de KALMAN, **sans apprentissage**

[SemanticKITTI 19] J. Behley *et al.*, « SemanticKITTI : A Dataset for Semantic Scene Understanding of LiDAR Sequences », *ICCV*, 2019.

06

Vers des données davantage structurées






Quand la structure n'est plus (seulement) la géométrie

Les deux idées de la thèse appliquées à des données davantage structurées

- 1) les interactions d'ordre supérieur apportent la robustesse
- 2) la percolation gouverne les performances



trait plein : attraction pointillés : répulsion


trait gras : arête satisfaite (trait fin : non satisfaite)

Graphes signés : les liens *créent* les communautés

[Asilomar 25]

[Asilomar 25] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « Higher-order Monte Carlo cluster dynamics for community detection in Euclidean graphs », Asilomar, 2025.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.




Images : extraire des réseaux de fissures **[EUVIP 26]**

© Cerema



Détection de communautés sur graphes signés : un cadre bayésien

Détection de communautés [Avrachenkov–Dreveton 22] : retrouver les communautés cachées Σ d'un graphe dont les liens sont *signés*



- ▶ $W_e > 0$ encode une **attraction** ; $W_e < 0$, une **répulsion** ; $|W_e|$ mesure la force de l'interaction
- ▶ Dans le cas étudié, le canal calibré donne une loi *a posteriori* de GIBBS signée [I&I 26+] :


$$U(\sigma) = -\log \mu_0(\sigma \mid X) + \sum_{\substack{e=\{i,j\} \\ W_e > 0}} W_e \mathbb{I}_{\{\sigma_i \neq \sigma_j\}} + \sum_{\substack{e=\{i,j\} \\ W_e < 0}} |W_e| \mathbb{I}_{\{\sigma_i = \sigma_j\}}, \quad \mu(\sigma) = \frac{e^{-U(\sigma)}}{Z}$$

[Avrachenkov–Dreveton 22] K. Avrachenkov, M. Dreveton, *Statistical Analysis of Networks*, Now Publishers, 2022.

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.



Un pas de Swendsen–Wang signé



$$\mathbb{P}(e \text{ gelée} \mid \sigma) = \begin{cases} 1 - e^{-|W_e|}, & e \text{ satisfaite} \\ 0, & e \text{ non satisfaite} \end{cases}$$

- Pour deux classes et un *a priori* uniforme, chaque composante gelée est **retournée en bloc** avec probabilité 1/2 : la transition est réversible et préserve μ [Swendsen–Wang 87]
- Dans la preuve, un pas depuis Σ produit une **réplique couplée de la loi *a posteriori*** $\Sigma^{(1)}$


[Swendsen–Wang 87] R. H. Swendsen, J.-S. Wang, « Nonuniversal critical dynamics in Monte Carlo simulations », *Physical Review Letters*, 1987.




Généraliser Swendsen–Wang aux interactions d'ordre supérieur

$$U(\sigma) = U_0(\sigma) + \sum_{b \in \mathcal{B}} U_b(\sigma), \quad b = \text{arête, triangle, clique...}$$

Triangle **attractif**
tout ou rien



Triangle **répulsif** (frustré)
jamais les deux arêtes




► Un **seul tirage par motif** : on introduit de la **corrélation** dans le processus de gel **[Asilomar 25] [I&I 26+]**

[Asilomar 25] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « Higher-order Monte Carlo cluster dynamics for community detection in Euclidean graphs », Asilomar, 2025.

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.



La percolation borne le recouvrement des communautés




[Sankararaman–Baccelli 18] A. Sankararaman, F. Baccelli, « Community detection on Euclidean random graphs », *ACM–SIAM SODA*, 2018.

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.




L'échelle des seuils du GSBM triangulaire



- Gel SW 0,6736 < triangles 0,7192 < percolation de l'information 0,7947 < **record rigoureux 0,8094**
- Point multicritique de Nishimori 0,8358 : conjecture




Validation à 10^6 nœuds : les trois régimes



$p = 0,70$: seules les arêtes standard percolent ; l'*overlap* reste au bruit




Validation à 10^6 nœuds : les trois régimes



$p = 0,72$: toutes les dynamiques percolent... mais l'*overlap* reste au bruit (nécessaire $\neq$ suffisant)




Validation à 10^6 nœuds : les trois régimes




$p = 0,80$: composantes géantes stables et **recouvrement effectif**


Extraction de réseaux de fissures sur images




intensité



profondeur



similarité d'arête



squelette extrait

- ▶ Du **pixel** (filtre de FRANGI [Frangi 98], qui juge chaque pixel seul et se fragmente sous le bruit) à la **paire de pixels** (graphe de FRANGI [GRETSI 25])
- ▶ **Multimodal** au niveau de l'**opérateur** : on somme les hessiennes normalisées, jamais les réponses [EUVIP 26]
- ▶ Transferts exploratoires sans réentraînement ; sortie sous forme de **graphe éditable**

[Frangi 98] A. F. Frangi, W. J. Niessen, K. L. Vincken, M. A. Viergever, « Multiscale vessel enhancement filtering », MICCAI, 1998.


[GRETSI 25] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Généralisation du filtre de Frangi pour l'extraction des réseaux de fissures », GRETSI, 2025.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.



La hessienne : l'information sur les structures *tubulaires*

$\mathcal{H}_\sigma(x) = \nabla^2(G_\sigma * I)(x)$, symétrique réelle : axes propres e_1, e_2 , demi-axes $1/\sqrt{|\lambda_1|}$ et $1/\sqrt{|\lambda_2|}$



Le filtre de FRANGI [Frangi 98] en tire **deux** nombres :

- ▶ $R_B = \frac{|\lambda_1|}{|\lambda_2|}$: la **forme**
0 pour une crête très allongée, 1 pour un disque
- ▶ $S = \sqrt{\lambda_1^2 + \lambda_2^2}$: le **contraste**
la force des courbures


$$\exp\left(-\frac{R_B^2}{2\beta^2}\right) \left(1 - \exp\left(-\frac{S^2}{2c^2}\right)\right) \quad \text{si } \lambda_2 > 0, \quad 0 \text{ sinon}$$

la réponse de FRANGI : une crête sombre et contrastée



Ce que le graphe ajoute : l'*alignement*

Le filtre juge chaque pixel **seul** ; le graphe demande que les directions e_1 des **deux** pixels concordent




$$S_{\text{align}} = \exp \left[-\frac{1}{2} \left(\frac{\sin(\theta(x_i) - \theta(x_j))}{s_a} \right)^2 \right]$$

le sinus, car θ et $\theta + \pi$ décrivent le même axe **[GRETSI 25] [EUVIP 26]**

[GRETSI 25] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Généralisation du filtre de Frangi pour l'extraction des réseaux de fissures », GRETSI, 2025.
[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.

Un fond granulaire : l'ordre 2 coupe les ponts parasites



visible granulaire

réponse de FRANGI au pixel

similarité de FRANGI


composante retenue en bleu

- ▶ Chaque caillou porte une réponse : le fond est aussi « crête » que la fissure
- ▶ Une **chaîne d'arêtes** suffit alors à relier les cailloux de proche en proche : le fond percole
- ▶ À l'**ordre 2**, deux arêtes ne se recollent que par un **triangle** : une chaîne sans triangle ne propage plus la connexité, et la vitesse de percolation croît avec K [ANS 26] : d'où le choix $K = 2$ [EUVIP 26]

[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.

De la similarité au squelette : la chaîne d'extraction



- ▶ **Seuiller** les arêtes puis les sommets (une seule fraction τ), garder les **composantes** assez grandes : une seule sur FIND, toutes ailleurs
- ▶ **Arbre couvrant minimal** par composante : la réponse épaisse devient une structure d'axe unique [EUVIP 26]
- ▶ **Centralité pondérée sur l'arbre**, en $\mathcal{O}(|V|)$: masses des sous-arbres accumulées, réenracinement au maximum, élagage descendant ; seul l'axe principal reste
- ▶ **La suite, à l'ordre 2** : deux arêtes ne se recollent que par un **triangle** [ANS 26] [ISPRS 26+]

Sur FIND, **sans apprentissage** : 63 % de JACCARD en fusionnant les trois modalités (60 % à deux) ; CrackSegDiff, supervisé, atteint 87 % sur données propres, mais s'effondre sous le bruit


[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.

[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.

[ISPRS 26+] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, article en préparation pour l'*ISPRS Journal of Photogrammetry and Remote Sensing*, 2026.




VT-GraF : la connexité $K = 2$ sur le terrain



- ▶ Visible granulaire + thermique : la réponse de Frangi seule est noyée dans les cailloux
- ▶ Les composantes triangles-connexes éliminent les artefacts granulaires



Sans entraînement... et robuste




Vaches Noires : vérité (vert), nous (rouge), U-Net + *transfer learning* (bleu)


- ▶ Compétitif avec un U-Net ayant coûté deux jours d'annotation experte
- ▶ CrackSegDiff : 87 % vs. 63 % de Jaccard sur données propres... mais s'effondre hors distribution



Transferts sans réentraînement




Palais des Papes : la fracture principale



CrackForest : Jaccard 78 %, Wasserstein 5 px



Sensibilité aux paramètres



Seuil relatif τ : optimum net vers $\tau \approx 0,2$ (graphe fragmenté vs. ponts parasites)

07

Perspectives : la voie hiérarchique






Retour au début : le théorème d'impossibilité de Kleinberg

Une fonction de *clustering* $\mathcal{C}$ associe à un espace métrique fini $(\mathcal{X}, d)$ une **partition** de $\mathcal{X}$

- (i) **Invariance d'échelle** : $\mathcal{C}(\mathcal{X}, \lambda d) = \mathcal{C}(\mathcal{X}, d)$
- (ii) **Richesse** : toute partition est atteinte
- (iii) **Cohérence** : resserrer un amas rendu par $\mathcal{C}$, ou écarter deux de ces amas, ne change rien



compatibles deux à deux,
jamais trois à trois

Impossibilité [Kleinberg 02] : aucune $\mathcal{C}$ ne satisfait les trois

CARLSSON & MÉMOLI ont trouvé la solution, et elle est **hiérarchique** : c'est le **Single-Linkage** [Carlsson-Mémoli 10]


[Kleinberg 02] J. Kleinberg, « An impossibility theorem for clustering », *Advances in Neural Information Processing Systems (NIPS)*, vol. 15, MIT Press, p. 446–453, 2002.
[Carlsson-Mémoli 10] G. Carlsson, F. Mémoli, « Characterization, stability and convergence of hierarchical clustering methods », *JMLR*, 2010.



Une dynamique de clusters **hiérarchique**

$\xi_e \sim \text{Exp}(|W_e|)$ si e est satisfaite, $\xi_e = +\infty$ sinon ;

$\Pi_\beta =$ composantes connexes du graphe $(V, \{e : \xi_e \leq \beta\})$, $0 \leq \beta \leq 1$



► En coupant aux **feuilles**, on retrouve GLAUBER ; en coupant aux **racines**, SWENDSEN-WANG

► La coupe la plus prometteuse pour le **recouvrement faible** : la **température de percolation** [I&I 26+]

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.



La hiérarchie Swendsen–Wang coupée à β , vue par Edwards–Sokal

EDWARDS–SOKAL [Edwards–Sokal 88] : tirer le couple (σ, ω) plutôt que σ seul, ω étant l'ensemble des arêtes gelées avant la date β

$$\nu_\beta(\sigma, \omega) \propto \underbrace{\mu_0(\sigma) e^{-(1-\beta)U(\sigma)}}_{\text{a priori chargé de l'énergie résiduelle}} \prod_{e \in \omega} (1 - e^{-\beta|W_e|}) \mathbb{I}_{\{e \text{ satisfaite}\}} \prod_{e \notin \omega} e^{-\beta|W_e|}$$

- **Marginale en σ** : sommer sur ω donne $e^{-\beta U(\sigma)}$; le poids $(1 - \beta)U$ mis dans l'*a priori* complète l'exposant : $\mu(\sigma) \propto \mu_0(\sigma) e^{-U(\sigma)}$ pour tout β
- **Sachant σ , le gel** : arête satisfaite gelée avec probabilité $1 - e^{-\beta|W_e|} = \mathbb{P}(\xi_e \leq \beta) : \omega = \{\xi_e \leq \beta\}$, ses amas sont Π_β , et les mêmes horloges servent à tous les β (emboîtement)
- **Sachant ω , le recoloriage** : chaque amas est retourné en bloc ou non, selon $\mu_0(\sigma) e^{-(1-\beta)U(\sigma)}$: les amas de Π_β interagissent encore par les arêtes non gelées ; à $\beta = 1$, retournements uniformes et indépendants (SWENDSEN–WANG)
- Au nœud u du dendrogramme, la coupe E_u est vue à sa date de fusion β_u : le facteur $e^{(1-\beta_u)\Lambda_u(\sigma)}$ du retournement exact est ce poids résiduel [I&I 26+]

[Edwards–Sokal 88] R. G. Edwards, A. D. Sokal, « Generalization of the Fortuin–Kasteleyn–Swendsen–Wang representation and Monte Carlo algorithm », *Physical Review D*, 38(6), 1988.

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.



Retourner un amas : la loi exacte

Un tirage d'horloges fixe le dendrogramme D ; reste à décider, à chaque fusion, **quels amas retourner**

$$\nu(\sigma \mid D) \propto \mu_0(\sigma) \prod_u \Lambda_u(\sigma) e^{(1-\beta_u) \Lambda_u(\sigma)}$$

$$\Lambda_u(\sigma) = \sum_{e \in E_u} |W_e| \mathbb{I}_{\{e \text{ satisfaite}\}} \quad (\text{poids satisfait de la coupe}) \quad \beta_u = \min_{e \in E_u, e \text{ satisfaite}} \xi_e \quad (\text{date de la fusion})$$


Au nœud u , où $C = C_1 \sqcup C_2$: **un seul tirage à quatre états σ^{ab}** , et non deux retournements indépendants

$$p_u(a, b \mid \sigma, D) = \frac{q_u^{ab}}{\sum_{c,d \in \{0,1\}} q_u^{cd}}, \quad q_u^{ab} = \mu_0(\sigma^{ab}) \prod_{v \succeq u} \Lambda_v(\sigma^{ab}) e^{(1-\beta_v) \Lambda_v(\sigma^{ab})}$$

- Seuls u et ses **ancêtres** se recalculent ; bain thermique exact, donc **balance détaillée** et μ invariante
[I&I 26+]

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.

Quelle coupe choisir ? Celle où les amas **percolent**




densité d'arêtes ouvertes avant β : $q_p(\beta) = p(1 - e^{-u_p\beta})$, $u_p = \log \frac{p}{1-p}$;
coupe critique β_c : $q_p(\beta_c) = q_c$, le seuil de percolation du réseau

- ▶ Seule une masse **macroscopique** transporte de l'information : c'est ce que dit la borne de recouvrement de la partie précédente, évaluée à l'horizon $\beta = 1$
- ▶ Sur la grille triangulaire, au seuil de percolation de l'*information*, le temps informationnel et β_c **coïncident** [I&I 26+] : le meilleur argument dont nous disposons pour dire que c'est la bonne coupe
- ▶ **Statut : un programme.** Notre meilleure borne rigoureuse vient d'une *autre* source (un canal d'information à plusieurs états sur les triangles) et *pas* de cette dynamique

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.




Calibration exacte sur le SBM



- ▶ Deux répliques, deux dendrogrammes **indépendants**, coupés au même β_c
- ▶ Chaque branche transmet exactement θ^2 : la densité d'évolution répliquée redonne $d\theta^2 = 1$
(le seuil de KESTEN–STIGUM, identité valable pour **toute** coupe exactement marginalisée : elle calibre le décompte, elle ne désigne pas β_c)
- ▶ Quand le signal diverge, $\beta_{c,n} \rightarrow 0$: la coupe s'écrase d'elle-même sur GLAUBER



L'adapter sans le réentraîner : *LoRA*




- ▶ On **gèle** le tronc pré-entraîné, on n'apprend qu'une correction de **petit rang** $W = W_0 + BA$ [LoRA 22]
- ▶ **CrackSAM** [CrackSAM 24] : 4,4 M de poids appris sur les 637 M de SAM
- ▶ SAM a déjà tout vu : lui donner en plus nos descripteurs (hessienne, gradient) ne change **rien**
- ▶ Et il **transfère** : des fissures de chantiers jamais vus, sans rien réapprendre

[LoRA 22] E. J. Hu et al., « LoRA : low-rank adaptation of large language models », *ICLR*, 2022.

[CrackSAM 24] K. Ge et al., « Fine-tuning vision foundation model for crack segmentation in civil infrastructures », *Construction and Building Materials*, 2024.



Comment guider l'attention *via* la hiérarchie ? Une idée à explorer



- L'**attention** : chaque jeton pose une **requête**, la compare aux **clefs** de tous les autres, et repart avec la moyenne de leurs **valeurs**, pondérée par un **score visuel** que SAM sait déjà calculer
- On y **ajoute un bonus** avant le *softmax* : un échange **favorisé**, jamais imposé [Graphormer 21]
- Le bonus vient de la **hiérarchie** du graphe de FRANGI : plus deux jetons **fusionnent tôt** dans l'arbre, plus il est fort, même loin dans l'image [EUVIP 26] ; LoRA l'apprend avec un **seul** coefficient β [LoRA 22]


$$\text{attention} = \text{softmax}(\text{scores visuels} + \beta B_H)$$

[Graphormer 21] C. Ying *et al.*, « Do Transformers really perform badly for graph representation ? », *NeurIPS*, 2021.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », *EUVIP*, 2026.

[LoRA 22] E. J. Hu *et al.*, « LoRA : low-rank adaptation of large language models », *ICLR*, 2022.

SAM gelé, LoRA et la hiérarchie : le montage



- **SAM reconnaît les fissures et le fond : ses poids restent gelés [SAM 2 24]**
- **L'arbre rapproche** deux morceaux d'une même fissure reliés par une chaîne de raccords compatibles, même loin dans l'image : le bonus B_H est d'autant plus fort que leur **fusion** dans le graphe de FRANGI est **précoce [EUVIP 26] [MALIS 09]**
- **LoRA apprend avec ce guidage**, pondéré par un **seul** coefficient β , parti de zéro [LoRA 22]

Objectif : moins de **ruptures**, pas plus de **faux raccords** — témoin : la simple proximité spatiale. **Rien n'est encore mesuré**

[SAM 2 24] N. Ravi *et al.*, « SAM 2 : segment anything in images and videos », 2024.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.

[MALIS 09] S. C. Turaga, K. L. Briggman, M. Helmstaedter, W. Denk, H. S. Seung, « Maximin affinity learning of image segmentation », NIPS, 2009.

[LoRA 22] E. J. Hu *et al.*, « LoRA : low-rank adaptation of large language models », ICLR, 2022.

08 Conclusion





Deux fils conducteurs, quatre contributions

1) Quand les relations binaires sont insuffisantes ou instables, les **interactions d'ordre supérieur** apportent une cohérence robuste.

2) La **percolation** est la clef de voûte théorique pour quantifier les performances de ces algorithmes

- ▶ Une **vue unifiée** du *Single-Linkage* : heuristique, géométrique, statistique [ANS 26] ; LiDAR 3D et 4D sans apprentissage
- ▶ **HGP-Clusterer** : la hiérarchie K -NN exacte, via Čech, GABRIEL et DELAUNAY d'ordre K [EUSIPCO 24] [CN 24] [ANS 26]
- ▶ La **vitesse de percolation** : elle explique l'échec de Robust SL et (H)DBSCAN, et les gains des K -polyèdres [SIGMETRICS SRC 24]
- ▶ L'**export du paradigme** : graphes signés [Asilomar 25] [I&I 26+] ; imagerie, graphe de FRANGI multimodal [GRETSI 25] [EUVIP 26] [ISPRS 26+]

[EUSIPCO 24] L. Hauseux, K. Avrachenkov, J. Zerubia, « Benefits of hypergraphs for density-based clustering », *EUSIPCO*, Lyon, 2024.

[CN 24] L. Hauseux, K. Avrachenkov, J. Zerubia, « Hypergraphs, percolation and hierarchical clustering », *Complex Networks & Their Applications*, Istanbul, 2024.

[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.

[SIGMETRICS SRC 24] L. Hauseux, « How can we theoretically measure the performance of density-based clustering algorithms ? », *ACM SIGMETRICS SRC*, Venice, 2024 (2^e prix).

[Asilomar 25] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « Higher-order Monte Carlo cluster dynamics for community detection in Euclidean graphs », *Asilomar*, 2025.

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.

[GRETSI 25] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Généralisation du filtre de Frangi pour l'extraction des réseaux de fissures », *GRETSI*, 2025.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », *EUVIP*, 2026.

[ISPRS 26+] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, article en préparation pour l'*ISPRS Journal of Photogrammetry and Remote Sensing*, 2026.



Autres perspectives

- ▶ **La grande dimension** : une **réduction de dimension** d'ordre supérieur, là où les méthodes courantes s'appuient sur des graphes de voisinage (UMAP)
- ▶ **Question ouverte** : HGP-Clusterer n'est que *fractionnellement* consistant ; un algorithme consistant en dimension $p \geq 2$ reste à inventer

Publications

Journal

- ▶ **[ANS 26]** *Generalization of Single-Linkage with higher-order interactions*, *Applied Network Science*, 2026

Conférences internationales et nationales

- ▶ **[CN 23]** Filaments de galaxies, Complex Networks, Menton, 2023
- ▶ **[EUSIPCO 24]** Hypergraphes pour le *clustering* par densité, EUSIPCO, Lyon, 2024
- ▶ **[CN 24]** Hypergraphes, percolation et *clustering* hiérarchique, Complex Networks, Istanbul, 2024
- ▶ **[SIGMETRICS SRC 24]** Mesure théorique de performance, ACM SIGMETRICS SRC, Venise, 2024 (2^e prix)
- ▶ **[Asilomar 25]** Dynamiques d'amas d'ordre supérieur, Asilomar, 2025
- ▶ **[GRETSI 25]** Généralisation du filtre de Frangi, GRETSI, Strasbourg, 2025
- ▶ **[EUVIP 26]** Extraction multimodale de fissures sans apprentissage, EUVIP, Luxembourg, 2026

En cours

- ▶ **[I&I 26+]** Cadre bayésien pour la détection de communautés sur graphes signés (journal)
- ▶ **[ISPRS 26+]** Graphe de Frangi généralisé, multimodal et sans apprentissage (journal ISPRS)

Logiciels *Open source* : dépôts GitHub Ayana-Inria/HypergraphPercol_K2 et Ayana-Inria/Frangi-EUVIP



Bibliographie (1/4)

- ▶ [Cameron–Martin 44] R. H. Cameron, W. T. Martin, « Transformations of Wiener integrals under translations », *Annals of Mathematics*, 45(2), 1944.
- ▶ [Florek 51] K. Florek, J. Łukaszewicz, J. Perkal, H. Steinhaus, S. Zubrzycki, « Sur la liaison et la division des points d'un ensemble fini », *Colloq. Math.*, 1951.
- ▶ [Schilder 66] M. Schilder, « Some asymptotic formulas for Wiener integrals », *Transactions of the AMS*, 125(1), 1966.
- ▶ [Gower–Ross 69] J. C. Gower, G. J. S. Ross, « Minimum spanning trees and Single-Linkage cluster analysis », *JRSS C*, 1969.
- ▶ [Hartigan 81] J. A. Hartigan, « Consistency of Single Linkage for high-density clusters », *JASA*, 1981.
- ▶ [Forina 83] M. Forina, C. Armanino, S. Lanteri, E. Tiscornia, « Classification of olive oils from their fatty acid composition », 1983 (jeu de données).
- ▶ [Swendsen–Wang 87] R. H. Swendsen, J.-S. Wang, « Nonuniversal critical dynamics in Monte Carlo simulations », *Physical Review Letters*, 1987.
- ▶ [Edwards–Sokal 88] R. G. Edwards, A. D. Sokal, « Generalization of the Fortuin–Kasteleyn–Swendsen–Wang representation and Monte Carlo algorithm », *Physical Review D*, 38(6), 1988.
- ▶ [Ester 96] M. Ester, H.-P. Kriegel, J. Sander, X. Xu, « A density-based algorithm for discovering clusters » (DBSCAN), *KDD*, 1996.
- ▶ [Meester–Roy 96] R. Meester, R. Roy, *Continuum Percolation*, Cambridge Tracts in Mathematics 119, Cambridge University Press, 1996.



Bibliographie (2/4)

- ▶ [Frangi 98] A. F. Frangi, W. J. Niessen, K. L. Vincken, M. A. Viergever, « Multiscale vessel enhancement filtering », MICCAI, 1998.
- ▶ [Kleinberg 02] J. Kleinberg, « An impossibility theorem for clustering », *Advances in Neural Information Processing Systems (NIPS)*, vol. 15, MIT Press, p. 446–453, 2002.
- ▶ [Penrose 03] M. Penrose, *Random Geometric Graphs*, Oxford University Press, 2003.
- ▶ [Berlinet–Thomas-Agnan 04] A. Berlinet, C. Thomas-Agnan, *Reproducing Kernel Hilbert Spaces in Probability and Statistics*, Kluwer, 2004.
- ▶ [Ghrist 08] R. Ghrist, « Barcodes : the persistent topology of data », Bulletin of the AMS, 2008.
- ▶ [MALIS 09] S. C. Turaga, K. L. Briggman, M. Helmstaedter, W. Denk, H. S. Seung, « Maximin affinity learning of image segmentation », *NIPS*, 2009.
- ▶ [Chaudhuri–Dasgupta 10] K. Chaudhuri, S. Dasgupta, « Rates of convergence for the cluster tree », *Advances in Neural Information Processing Systems (NIPS)*, vol. 23, p. 343–351, 2010.
- ▶ [Carlsson–Mémoli 10] G. Carlsson, F. Mémoli, « Characterization, stability and convergence of hierarchical clustering methods », *JMLR*, 2010.
- ▶ [Dembo–Zeitouni 10] A. Dembo, O. Zeitouni, *Large Deviations Techniques and Applications*, 2^e éd., Springer, 2010.
- ▶ [Campello 13] R. Campello, D. Moulavi, J. Sander, « Density-based clustering based on hierarchical density estimates » (HDBSCAN), *PAKDD*, 2013.
- ▶ [ToMATo 13] F. Chazal, L. J. Guibas, S. Y. Oudot, P. Skraba, « Persistence-based clustering in Riemannian manifolds » (ToMATo), *J. ACM*, 60(6), art. 41, 2013.



Bibliographie (3/4)

- ▶ [Biau–Devroye 15] G. Biau, L. Devroye, *Lectures on the Nearest Neighbor Method*, Springer, 2015.
- ▶ [Boissonnat 18] J.-D. Boissonnat, F. Chazal, M. Yvinec, *Geometric and Topological Inference*, Cambridge University Press, 2018.
- ▶ [Sankararaman–Baccelli 18] A. Sankararaman, F. Baccelli, « Community detection on Euclidean random graphs », *ACM–SIAM SODA*, 2018.
- ▶ [SemanticKITTI 19] J. Behley *et al.*, « SemanticKITTI : A Dataset for Semantic Scene Understanding of LiDAR Sequences », *ICCV*, 2019.
- ▶ [GPT-3 20] T. Brown *et al.*, « Language models are few-shot learners », *NeurIPS*, 2020.
- ▶ [Bommasani 21] R. Bommasani *et al.*, « On the opportunities and risks of foundation models », 2021.
- ▶ [Graphormer 21] C. Ying *et al.*, « Do Transformers really perform badly for graph representation ? », *NeurIPS*, 2021.
- ▶ [Avrachenkov–Dreveton 22] K. Avrachenkov, M. Dreveton, *Statistical Analysis of Networks*, Now Publishers, 2022.
- ▶ [LoRA 22] E. J. Hu *et al.*, « LoRA : low-rank adaptation of large language models », *ICLR*, 2022.
- ▶ [SAM 23] A. Kirillov *et al.*, « Segment Anything », *ICCV*, 2023.



Bibliographie (4/4)

- ▶ [Edelsbrunner–Osang 23] H. Edelsbrunner, G. Osang, « A simple algorithm for higher-order Delaunay mosaics and alpha shapes », *Algorithmica*, 2023.
- ▶ [Rolle–Scoccola 24] A. Rolle, L. Scoccola, « Stable and consistent density-based clustering via multiparameter persistence » (Persistable), *JMLR*, 25(258), 2024.
- ▶ [CrackSAM 24] K. Ge *et al.*, « Fine-tuning vision foundation model for crack segmentation in civil infrastructures », *Construction and Building Materials*, 2024.
- ▶ [SAM 2 24] N. Ravi *et al.*, « SAM 2 : segment anything in images and videos », 2024.
- ▶ [AYANA RA 25] Équipe-projet AYANA, « 3D LiDAR Instance Segmentation with Geometric Priors : The HGP-Clusterer », *Rapport annuel d'activité Inria 2025*, § 7.7.
- ▶ [ALPINE 25] C. Sautier, G. Puy, A. Boulch, R. Marlet, V. Lepetit, « Is clustering enough for LiDAR instance segmentation ? A state-of-the-art training-free baseline » (ALPINE), 2025.
- ▶ [Geo-4D 25] G. Oh, Y. Jang, J. Choi, S.-J. Kang, G. Lin, S. Kim, « Training-free global geometric association for 4D LiDAR panoptic segmentation » (Geo-4D), 2025.
- ▶ [Sonata 25] X. Wu *et al.*, « Sonata : self-supervised learning of reliable point representations », *CVPR*, 2025.
- ▶ [Concerto 25] Y. Zhang *et al.*, « Concerto : joint 2D–3D self-supervised learning emerges spatial representations », *NeurIPS*, 2025.
- ▶ [Utonia 26] Y. Zhang *et al.*, « Utonia : toward one encoder for all point clouds », 2026.