

PERCOLIA



Structuration automatique & fine de données.
Application au LiDAR 3D.

Louis HAUSEUX (porteur techno') & Alban HAUSEUX (porteur business)

Projet encadré par Stéphanie MORALES (Centre Inria d'Université Côte d'Azur)



Plan de la présentation

I) Constat (problème à résoudre)

II) Projet & Solution

III) Technologie

IV) Équipe

V) Marché & Concurrents

VI) Plan d'action

VII) Pourquoi Inria

I) Constat (problème à résoudre)




Exemple 1 : Détection d'anomalies de chantier (AIDetech)

Projet ISS de Marie Aspro avec Naval Group

- **Objectif** : Détection automatique d'anomalies sur chantiers navals.
- **Données** : Confrontation entre un **modèle 3D théorique** (chantier attendu) et des **captations LiDAR réelles** (chantier réel).
- **Collaboration Percolia** : Isoler les anomalies qui ne font pas partie du modèle théorique (ex. : casques de chantier, tuteurs, bâches).

Le verrou

- Nécessite un clustering assez fin prenant en compte le modèle 3D pour isoler proprement les anomalies de chantier.



Détection des anomalies (cubes et tuteurs colorés) par rapport au modèle 3D (en rouge) sur le benchmark de Marie ASPRO.


Exemple 2 : Jumeaux numériques urbains (Greehill)

Inventaire d'arbres intelligents (Greehill)

- ▶ Création de jumeaux numériques d'arbres urbains à partir de LiDAR mobiles.
- ▶ Analyse de la santé des arbres, risques de chute de branches et détection des obstacles (lignes électriques, voies).

Le verrou technologique

- ▶ Le feuillage se mêle aux lignes électriques, panneaux de signalisation ou façades.



Images extraites d'une présentation de Gyula FEKETE (CTO de Greehill).
1) segmentation sémantique 2) segmentation d'instance 3) résultat final



Exemple 3 : Cartographie du réseau électrique (Hydro-Québec)

Cartographie en forêt dense

- ▶ Repérer automatiquement les lignes électriques et les poteaux au milieu des arbres.
- ▶ Utilisation de LiDAR embarqués sur des véhicules.

Le verrou technologique

- ▶ Les branches et les feuilles se confondent avec les câbles, ce qui perturbe la détection automatique et impose un tri manuel laborieux.




Figure de Philippe MASSICOTTE (chercheur chez Hydro-Québec),
présentation au Grets 2025.



Exemple 4 : SLAM & Traitement LiDAR temps réel (Exwayz)

Qu'est-ce que le SLAM ?

- ▶ **Cartographie** : Construction d'une carte 3D de l'environnement.
- ▶ **Localisation** : Positionnement en temps réel du robot dans cette carte.

Le verrou technologique

- ▶ Problème circulaire (la localisation dépend de la carte et réciproquement).
- ▶ Le bruit relie à tort les objets dynamiques aux structures statiques (perte de tracking).



Logiciel de cartographie et localisation (SLAM) 3D temps réel (source : exwayz.fr).

II) Projet & Solution



Le standard de l'état de l'art du clustering : (H)DBSCAN

L'algorithme de clustering incontournable pour tous nos cas d'usage :

- ▶ C'est la brique de base utilisée par tous les leaders du secteur pour segmenter et structurer les nuages de points :
 - **Greehill** : Gyula FEKETE (CTO) et Benjamin BERTA (Lead Machine Learning).
 - **Hydro-Québec** : Philippe MASSICOTTE (Chercheur).
 - **Exwayz** : Hassan BOUCHIBA (Co-fondateur & CTO).

Pourquoi un tel succès ?

- ▶ **Principe simple** : Un clustering fondé uniquement sur la densité locale des points.
- ▶ **Grande disponibilité** : Intégré par défaut dans toutes les bibliothèques logicielles standards, le rendant universel et immédiat à déployer.

La limite critique :

- ▶ Face au bruit de mesure (poussières, occlusion), l'analyse purement binaire par paires de points fusionne à tort des structures disjointes (effet de chaînage).



La Solution Percolia (3D LiDAR)

Une technologie issue de la recherche Inria

- ▶ Notre logiciel de clustering non supervisé est né des travaux de thèse de Louis HAUSEUX au sein de l'Inria Sophia Antipolis.
- ▶ Nous proposons de le décliner sous trois formes, selon le besoin :

Trois modalités d'intégration de notre solution :

- ▶ **Conseil et intégration d'une *baseline* complète** : Analyse comparative sur les nuages de points réels de nos clients pour valider le gain de précision et de conformité.
- ▶ **API SaaS / Cloud** : Traitement et structuration à la demande des volumes massifs de données LiDAR 3D dans un cloud sécurisé.
- ▶ **Licence logicielle embarquée (Local / Offline)** : Pour les contraintes fortes de confidentialité ou une intégration directe dans les logiciels de capteurs (ex. YellowScan).



Au-delà du 3D LiDAR : Perspectives

Une technologie algorithmique générique et transverse :

- ▶ Le noyau de clustering de Percolia s'applique à d'autres types de données complexes et bruitées.

Trois perspectives de développement :

- ▶ **Logs de cybersécurité & finance** : Regroupement intelligent d'événements système (embeddings) pour la détection de fraudes.
- ▶ **Graphes signés & Bio-informatique** : Partitionnement de réseaux appliqué au séquençage d'ADN fin (inférence d'haplotypes).
- ▶ **Traitement d'images (Cerema)** : Détection automatique de fissures sur images (visible/thermique) supervisée par Josiane ZERUBIA.

III) Technologie



Rupture technologique : HGP-Clusterer

Les deux piliers scientifiques :


- ▶ **L'ordre supérieur** : connectivité multipoints (intersections de boules multiples) modélisant l'estimateur de densité $\hat{f}_{K\text{-NN}}$.
- ▶ **La percolation (seuil critique différé)** : retardement théorique de la connectivité globale bloquant la propagation du bruit.

Avantages & Optimisation

- ▶ **Training-Free** (non supervisé, robuste).
- ▶ **Priors géométriques** (ex: modèle 3D).
- ▶ **Rapide** (mosaïque de Delaunay d'ordre K , complexité quasi-linéaire $O(N \log N)$).

Standard (DBSCAN / Single-Linkage)

Effet de chaînage (1 seul cluster)



Percolia (HGP-Clusterer)

2 clusters bien séparés



IV) Équipe

Une équipe complémentaire : Science & Business

Louis Hauseux – porteur techno'

- ▶ Doctorat en informatique (Inria Sophia Antipolis).
- ▶ Normalien (ENS Paris-Saclay), double M2 en Mathématiques Fondamentales et Appliquées.
- ▶ Expert en percolation géométrique et structures d'ordre supérieur.
- ▶ **Rôle** : R&D, conception et implémentation du noyau algorithmique.

Alban Hauseux – porteur business

- ▶ Ingénieur Télécom (IMT Atlantique), Master Ingénierie Financière (Paris-Dauphine).
- ▶ Parcours en finance quantitative, audit et contrôle de modèles quantitatifs (Banque de France, HSBC, Société Générale).
- ▶ **Rôle** : Développement commercial, relation clients, audits et intégration logicielle.

Complémentarité & Conseil Scientifique

- ▶ **Synergie Science-Business** : Association d'un profil recherche de pointe (Louis) et d'un profil finance, audit de modèles et gestion des risques (Alban) garantissant la structure et la viabilité commerciale.
- ▶ **Conseil scientifique** : Soutenu et encadré par **Josiane Zerubia** (Directrice de Recherche Inria, équipe AYANA).

V) Marché & Concurrents



Marché et Positionnement Concurrentiel

Le marché du LiDAR & Jumeaux numériques

- ▶ **Dynamique du marché** : Cartographie LiDAR (5,3 Md\$ en 2025, proj. > 40 Md\$ en 2035) et jumeaux numériques (19 Md\$ en 2024).
- ▶ **Cibles logicielles** : Industriels exploitant des nuages de points 3D LiDAR (monitoring urbain/forestier, inspection, réseaux).
- ▶ **Exemples de cibles** : *Greehill*, *Exwayz*, *YellowScan*.

L'alternative standard : (H)DBSCAN

- ▶ **Atouts concurrentiels** : Entièrement libre d'utilisation, gratuit et open-source (Scikit-Learn).
- ▶ **Limites techniques** : Sensibilité au bruit (effet de chaînage reliant à tort des amas) et manque de précision fine.

La valeur ajoutée de Percolia

- ▶ **Segmentation robuste** : Insensibilité théorique et pratique au bruit de mesure (sans effet de chaînage).
- ▶ **Intégration facile** : API identique à Scikit-Learn (remplace directement 'DBSCAN' dans les pipelines existants).
- ▶ **Léger & Temps réel** : Complexité quasi-linéaire ($O(N \log N)$ via la mosaïque de Delaunay d'ordre K), pas besoin de cartes GPU coûteuses. *Inria*

VI) Plan d'action



Modèle Économique et Plan d'Action

Modèle Économique :

- ▶ **Audits payants** : Diagnostics comparatifs sur les nuages de points réels des clients pour démontrer le gain de précision.
- ▶ **API & Licences** : Vente d'abonnements récurrents (API SaaS Cloud) ou de licences logicielles embarquées (Local/Offline).

Plan d'action (Feuille de route ISS)

- ▶ **À 6 mois (LiDAR 3D)** :
 - Finaliser la solution logicielle (API & PI).
 - Créer les supports de démos et de communication.
 - Démarcher les industriels du LiDAR.
- ▶ **À 12 mois (Cyber / Fraude)** :
 - Finaliser la solution logicielle pour les logs informatiques.
 - Démarcher les acteurs de la cybersécurité et de la banque.

VII) Pourquoi Inria



Pourquoi Inria Startup Studio ?

Le partenaire stratégique et technologique :

- ▶ **Accompagnement (CPPI)** : Mentorat personnalisé pour structurer le business model et s'insérer dans le réseau industriel.
- ▶ **Cadre de transfert** : Transfert naturel de la propriété intellectuelle issue des travaux de thèse de Louis HAUSEUX.
- ▶ **Synergie technologique** : Complémentarité directe avec les bibliothèques géométriques Inria (CGAL, Geogram).
- ▶ **Crédibilité scientifique** : Gage de confiance indispensable auprès des clients grands comptes et des investisseurs.



Une transition naturelle de la
recherche académique à l'offre
industrielle.

Fin.



Backup 1 : Généralisation à l'axe Logs Cyber


Le problème : Les angles morts de sécurité

- ▶ **Exemple (Le Louvre - Abdelhadi)** : Des caméras de sécurité mal placées créent des angles morts facilitant l'intrusion.
- ▶ **En cybersécurité/fraude** : Le flux de logs est massif. Sans corrélation intelligente, des alertes isolées masquent des attaques complexes (angles morts).


L'approche Percolia :

- ▶ Transformation des logs informatiques en **embeddings** adaptés.
- ▶ Application de HGP-Clusterer pour regrouper les événements autour de sessions, IPs et comptes.
- ▶ Regroupement des logs liés pour réduire la masse d'alertes à analyser et faire émerger les comportements atypiques.


Hartigan's Model: High-Density Cluster Hierarchy




Hartigan's Model: High-Density Cluster Hierarchy




Hartigan's Model: High-Density Cluster Hierarchy




Hierarchical tree



Hartigan's Model: High-Density Cluster Hierarchy



Hierarchical tree



Clustering on Euclidean Data $\mathcal{X} \subset \mathbb{R}^d$: Estimation

f unknown



Estimation $\hat{f}$

Expensive naive methods
(discretization of $\mathbb{R}^d$)



Clustering on Euclidean Data $\mathcal{X} \subset \mathbb{R}^d$: Density Estimator

$$\hat{f} \leftarrow \hat{f}_{K\text{-NN}}$$

Estimator: K -Nearest Neighbors (K -NN)


$$\forall \mathbf{x} \in \mathbb{R}^d, \quad \hat{f}_{K\text{-NN}}(\mathbf{x}) = \frac{K}{n \omega_d r_K(\mathbf{x})^d}$$

$$r_K(\mathbf{x}) = \min \{r \geq 0 \mid |B(\mathbf{x}, r) \cap \mathcal{X}| \geq K\}$$

- ▶ n : number of points in $\mathcal{X}$
- ▶ ω_d : volume of the unit ball in $\mathbb{R}^d$
- ▶ $r_K(\mathbf{x})$: distance to the K -th nearest neighbor of $\mathbf{x}$
- ▶ $\omega_d r_K(\mathbf{x})^d$: volume of the ball containing the K neighbors




Clustering on Euclidean Data $\mathcal{X} \subset \mathbb{R}^d$: The Case $K = 1$



Poisson point cloud $\mathcal{X} \subset \mathbb{R}^2$



Clustering on Euclidean Data $\mathcal{X} \subset \mathbb{R}^d$: The Case $K = 1$




$$\begin{aligned}\hat{\lambda}(x) &\geq \lambda_0 \\ \Leftrightarrow r_1(x) &\leq r_0\end{aligned}$$

High-density level sets
= **Boolean model**



Clustering on Euclidean Data $\mathcal{X} \subset \mathbb{R}^d$: The Case $K = 1$




$$\hat{\lambda}(x) \geq \lambda_0$$
$$\Leftrightarrow r_1(x) \leq r_0$$

High-density clusters
= **Connected components** of
 $G(\mathcal{X}, r_0)$

Geometric graph [2]



Clustering on Euclidean Data $\mathcal{X} \subset \mathbb{R}^d$: The Case $K = 1$




$$r_1(x) \leq r_0$$

High-density clusters
= **Connected components** of
 $G(\mathcal{X}, r_0)$

Geometric graph [2]



Clustering on Euclidean Data $\mathcal{X} \subset \mathbb{R}^d$: The Case $K = 1$



$$r_1(x) \leq r_0$$


High-density clusters
= **Connected components** of
 $\text{MST}_{r_0}(\mathcal{X})$

Pruned Minimum Spanning Tree




Robust SL / (H)DBSCAN ($K = 2$)

Point cloud and balls of radius r



Hierarchical tree



The True 2-NN Hierarchy: Scale r


The diagram shows a hexameric protein complex composed of six subunits, labeled A through F, arranged in a ring. Each subunit is represented by a dashed circle. Subunits A and B are on the left, C and D are in the middle, and E and F are on the right. Subunit A has an arrow pointing to a specific region, likely indicating a site of interest. The subunits are connected by lines, suggesting interactions or a continuous polypeptide chain. The diagram is labeled with 'I', 'II', and 'III' at the bottom, which correspond to the domains described in the text.

Step 1: The 7 segments merge at threshold r .



The True 2-NN Hierarchy: Scale r'

Triangles and 3-intersections at r'



Hierarchical tree




Step 2: Merging of triangles at r' via 3-intersections. CD remains isolated.




The True 2-NN Hierarchy: Scale r''

Global connectivity at r''




Hierarchical tree




Step 3: Global connectivity at r'' through tangency points.

Robust SL vs. True 2-NN Hierarchy: Comparison

Robust SL Hierarchy ($K = 2$)



True 2-NN Hierarchy




Summary: The true 2-NN hierarchy isolates the connection bridge $C-D$, unlike Robust SL.



Clustering on Euclidean Data $\mathcal{X} \subset \mathbb{R}^d$: High-Density Clusters ($K \geq 2$)

- ▶ If $\hat{f} = \hat{f}_{K\text{-NN}}$ ($K \geq 2$): density estimator by K -nearest neighbors.
- ▶ Transition to **hypergraphs** (geometric complexes):
 - Edges and triangles appear at the intersections of balls of radius r .
- ▶ Higher-order clustering algorithms:
 - Connected components are replaced by **K -polyhedra**.
 - For $K \geq 2$, clusters (polyhedra) can overlap.





The Case $K = 1$: The Gabriel Graph


► **Definition:**

- An edge $[A, B]$ is a **GABRIEL** edge if its **diametral disk** does not contain any other point in $\mathcal{X}$.


► **Intermediate structure:**

- Key structure between the MST and the triangulation:

$$\text{MST} \subseteq \text{GABRIEL Graph} \subseteq \text{DELAUNAY}$$



Gabriel edge (empty)



Non-Gabriel (non-empty)


Generalization to Order K : Splitting Simplices

► K -splitting simplex:


- It is a K -simplex that has a **real influence** (causes clusters to merge) on the K -NN hierarchy.
- **Case $K = 1$:** 1-splitting simplices are precisely the **edges of the MST**.

► Gabriel condition:

- **Theorem:** any K -splitting simplex is necessarily a **Gabriel simplex** ($\hat{B}_\sigma \cap (\mathcal{X} \setminus \sigma) = \emptyset$).
- **Computational domain:** the **higher-order Delaunay mosaic** [1].



Gabriel triangle (empty)



Non-Gabriel (non-empty)



The K -Minimum Spanning Tree Analogy

Similar to $K = 1$, the higher-order hierarchy relies on a sparse combinatorial structure:

► **Percolation objects:**

- It is no longer points, but **facets** ($(K - 1)$ -simplices) that merge.

► **Gabriel simplices:**

- The simplices causing the merges (splitting simplices) are **Gabriel** simplices.

► **Computational domain:**

- The search is restricted to the simplices of the **higher-order Delaunay mosaic** [1].

Comparison 1-MST vs. K -MST

	$K = 1$	$K \geq 2$
Vertices	Points	$(K - 1)$ -simplices
Merges	Edges	K -simplices
Condition	GABRIEL	GABRIEL
Domain	DELAUNAY	Order- K DELAUNAY



Backup 4 : Résultats en Segmentation Temporelle 4D (SemanticKITTI)

- ▶ Suivi temporel d'instances sur des nuages de points 3D séquentiels.
- ▶ Combinaison de **HGP-Clusterer** avec du **Transport Optimal Déséquilibré** (*Unbalanced Optimal Transport*).
- ▶ Solution complètement **sans apprentissage** (comparée à Geo-4D ou Alpine).
- ▶ Élimination totale du besoin de réentraînement lors des changements de domaine de capteurs.



Backup 5 : Application à la Génomique (Haplotype Assembly)

1. Contexte biologique : Deux chromosomes homologues (Haplotypes)

Les humains sont diploïdes : ils possèdent deux copies de chaque chromosome.

Haplotype 1
(Vérité $\Sigma = +$)


Haplotype 2
(Vérité $\Sigma = -$)



Backup 5 : Application à la Génomique (Haplotype Assembly)

2. Séquençage haut débit : Reads d'ADN

Le séquençage génère de courts fragments chevauchants appelés **reads** issus des deux chromosomes.






Backup 5 : Application à la Génomique (Haplotype Assembly)

3. Modélisation sous forme de graphe signé

Nœuds = reads Arêtes = chevauchements (attractions / répulsions)

But : Reconstruire l'affectation d'haplotypes Σ à partir de ce graphe signé bruité.





Backup 6 : Détection de Communautés sur Graphes Signés

Détection de communautés sur graphes signés ($K = 2$)

- ▶ Partitionner les nœuds en $K = 2$ communautés : $\Sigma_i \in \{+1, -1\}$.
- ▶ Les liens représentent des **attractions** (pleins) et des **répulsions** (pointillés).
- ▶ Au-delà du SBM classique : couplage entre géométrie spatiale et structure de communauté !

Le défi géométrique

- ▶ Plongement spatial (ex: positions sur $\mathbb{Z}$ ou $\mathbb{R}^d$).
- ▶ Probabilités d'arêtes dépendant de la distance $r = \|x_i - x_j\|$:

$$\mathbb{P}(\text{arête attractive} \mid \text{même communauté}) = f_{\text{in}}(r)$$

$$\mathbb{P}(\text{arête attractive} \mid \text{communautés différentes}) = f_{\text{out}}(r)$$

- ▶ **Intérêt principal et verrou** : capturer cette géométrie sous-jacente.

References |

- [1] Georg Osang and Herbert Edelsbrunner.
A simple algorithm for higher-order Delaunay mosaics and alpha shapes.
Algorithmica, 85:277–295, 2023.
- [2] Mathew Penrose.
Random Geometric Graphs, volume 5 of *Oxford Studies in Probability*.
Oxford University Press, 2003.